提示词到可编辑多车任务地图

VRP 可视化路线的批判性调研与公平实验方案

研究快照 2026 年 10 月 7 日　适用对象 本科科研项目与工程原型

阅读重点：先看第 1 至 5 节的系统边界，再看第 9 至 10 节的算法取舍，实施时按第 15 至 20 节的实验和校验协议推进。

1 结论与实施决策

这条路线值得做。最稳妥的首版，是把自然语言变成带来源和单位的任务合同，在可编辑地图上确认车辆、任务与约束，再交给成熟固定求解器，最后由独立程序验算并显示分工、访问顺序、载重和时间。核心成果应是一个能解释、能编辑、能重算、能复查的多车任务系统。

研究价值优先放在两个位置：一是有歧义的需求怎样可靠落到结构化任务；二是生成的局部启发式能否在相同强求解框架、预算与隐藏测试集上产生可重复增益。算法推荐接口可以预留，默认仍使用保守的固定基线。当前项目中 5NN 和距离门控跨家族失败，不应再以“有推荐器”作为先进性的证明。

文献同时支持希望和克制。LLM 直接给路线在小任务或专门训练后可以有效，但规模、约束和输入表达变化仍会带来失败。2025 至 2026 年的 VRPAgent、AILS-AHD 及 CVRPLib 竞赛说明，LLM 设计局部算子已不只是玩具演示；它们依赖强元启发式、外部评价和搜索预算，不能归纳成“提示词一键取代求解器”。[N11][N12][N13][N17][N18][N26]

立即采用：版本化 TaskSpec、人工可编辑任务地图、固定求解器、独立 checker、来源清单与失败日志。并行研究：同任务的固定算法、算法选择、直接路线、生成代码四路对照。暂缓：把自由生成整套算法放到默认执行链、未经证据的 LLM 推荐器、以 3D 动画替代约束正确性，以及宣称机器人可直接安全行驶。

本报告是截至 2026 年 10 月 7 日的有界批判性调研。它核对论文正文重点章节、作者仓库、官方数据及工具文档，不声称穷尽所有文献，也未在本次调研中复现这些外部论文。当前实验状态仅按项目交接材料引用，不把未终态试验预先排出赢家。后续章节中的方案、预算和闸门均是建议，不能读成已经跑通的结果。

2 先分清任务再设计系统

“可视化路径”涉及至少四个不同对象：地图上的几何与拓扑、任务由谁完成、每车以何顺序访问、车辆怎样连续运动。首版应解决点任务的分配与访问顺序。路径折线、时间轴与动画只是这些结果的不同表达。

格子可以用于编辑、区域选择和聚合，但把所有任务强行量化成同样大小的格子会改变距离、可达性和需求密度。应保留原任务点和真实路网，格子作为视图；只有在研究本身就是离散栅格规划时，格子才是求解状态。真实农田边界可用于覆盖轨道，却不能自动提供服务时长、地头转向、出入口和车辆协同条件。

建议的主链是：输入与数据导入 → 语义和单位检查 → 版本化任务合同 → 可编辑任务地图 → 矩阵与可达性 → 固定或实验求解器 → 独立校验 → 路线、任务、时间轴和证据。每一箭头都有明确输入输出；显示层不得回写并暗改求解事实。

若后续确需区域覆盖，应先由覆盖规划器把地块转成服务路径与成本，再在更高层安排多车任务。若确需狭窄通道内多机器人同步运动，还需增加时间扩展图、冲突消解、速度/转弯模型及安全验证。多车 VRP 给出访问顺序，并不自动保证连续轨迹无碰撞。

问题层	决定什么	不能替代什么
地图与最短路	道路连接、方向、合法转场及成本	车辆任务分配
VRP	任务分配、每车访问次序、容量与时窗	连续控制与避碰
CPP 覆盖	区域内部服务路径、覆盖率、转向	跨地块多车运营安排
MAPF 或轨迹规划	带时间的冲突消解与运动可执行性	业务需求语义与 VRP 目标

3 检索范围与证据如何分级

调研采用多轮定向检索加引用回溯：先查自然语言建模、直接组合优化、程序搜索三类，再回溯 VRP 专门工作，补查 2026 年的新论文与作者仓库，最后把性能主张与数据、预算、强基线和发布状态交叉核

对。正式论文页、arXiv 版本、作者 repo、数据维护机构与官方文档优先。检索明细、纳入依据、阅读深度和限制在随附来源 CSV 及机器清单中。

纳入条件是能影响本项目的架构选择、数据可信度、验证方法、复现可行性或公平比较。相关综述只用于分类和发现原文；不能用综述中的转述替代原论文证据。排除与车辆路径无关的“LLM 模型路由”基准、没有可核方法的营销视频，以及只证明图像或场景好看但未验证任务约束的演示。农业轨迹和覆盖数据保留为边界对照，不能混入 VRP 运营成绩。

阅读深度分为：原文定点核读（已检查方法、关键实验和指定附录）；原文概览；摘要；官方文档或记录。下载全文不等于逐页精读，官方 repo 存在不等于已跑通。所有本次未复现的外部结果都保留这一状态。代码可用性按“完整研究管线可见、部分算子发布、占位或未核实”记录，避免把一个 README 当作实现。

两项特别重要的审计结果是：FunSearch 官方发布不包含原语言模型、执行沙箱和分布式系统；PyVRP+论文给出的仓库链接，在本次访问时只有 README 占位。VRPAgent 官方则明示是生成算子的 early release。论文结论可以讨论，但实施计划不能假定这些系统均能直接安装复现。[N01][N17][N19]

证据强度也应分开：官方竞赛验证支持某条解和成绩确实登记；它不自动证明 LLM 是成绩提升的唯一原因。论文消融支持所测条件下的模块作用；它不自动证明跨城市、跨约束和当前版本仍成立。新预印本并非应排除，但应清楚标注其验证范围。

4 自然语言应落到可追溯任务合同

LLM 的第一份输出应是受约束的结构化草稿，不是地图事实。TaskSpec 至少含问题类型、目标顺序、地图坐标系与版本、任务、车辆、成本矩阵、硬软约束、单位、来源和未知项。必须允许“未知”和“多候选”，不能为了凑齐 JSON 把缺失事实默默补成真值。

每个重要字段保留来源状态：用户明确给出、官方数据读取、确定性推导、暂定假设、仍未知。例：“5 辆车”可直接抽取；“尽快送完”不能自动等同最短总距离，它可能指最早完工、最少迟到或最小最大工作量。不能每个细节都反复追问，但会改变可行域或目标的歧义必须在预览中显式暴露，并允许用户一次性修改。

地点名称需要地理实体匹配和入口确认。同名地点、建筑中心点与车辆入口、路网吸附到平行道路，都可能改变可达性。用户仅说“生成一个物流场景”时，可以采用带种子和参数的合成任务；用户说“按实际情况”时，应使用真实来源并把仍合成的需求、时窗和服务时间逐字段标出。

容量和需求应使用向量与单位，例如重量、体积或件数，不能混加；时窗必须明确是到达、开始服务还是完成服务的时限；配送与取货要写明载重更新顺序；返仓、开放路线、多仓、车辆资格、任务优先级也要成为显式字段。必要字段缺失时可返回可编辑草稿，但不得将结果标为“已验证可执行”。

随附 task_contract.json 给出了建议的字段组与编辑规则。它是研究合同草案，尚非实现好的 API。后续实现宜采用固定 schema 与确定性适配器，把 LLM 限制在填值和提出可审查约束上。对稳定问题类型，维护模板比每次自由生成建模代码更容易审计。NL4Opt、OptiMUS 和 DRoC 可支持这一分层思路，但不提供真实地图语义自动正确的保证。[N08][N09][N05]

5 可编辑地图怎样才有科研价值

界面应同时提供三种视图：空间地图用于确认任务位置和道路；任务表用于编辑需求、时窗、服务时长和车辆资格；路线与时间轴用于检查各车访问顺序、等待、载重和未服务任务。只显示几条彩线，用户无法判断它是否漏点、超载或把迟到藏起来。

输入编辑必须产生新版本。移动任务点、改容量、增删车辆或切换目标都会改变 spec_hash，旧解立即成为“待重算”。仍可将旧解作为比较层显示，但不能继续挂着绿色“已验证”标记。撤销和重做也应回到明确的任务版本，保证图表、输入和实验日志可以互相追溯。

地图表达要遵守求解语义：欧氏实验用直线且明确“平面距离”；真实路网路线使用与成本矩阵一致的道路路径，保留原点、吸附点和入口。路由服务返回不可达时，不能画一条穿河或穿围墙的直线来补齐。若只得到示意连线，应直接标成示意，并与可行性状态分离。

至少展示任务总数/已服务数、每车任务数与载重峰值、距离、驾驶/服务/等待时间、迟到或违反约束、未分配原因、求解器与版本、运行预算、独立校验状态。若没有最优性证明，写“当前找到的最好可行解”；若参照 BKS，注明 BKS 日期与口径，避免把它叫理论最优。

科研面板应能切换同一实例的四路结果、观察失败实例、查看分布外性能与预算曲线。不要把整体平均分放在最显眼处却隐藏不可行比例。模型解释可以帮助理解，但所有展示数字都应来自结构化运行记录和 checker 重算，不从 LLM 叙述中提取。图形层的成功标准是降低核验成本，而不是增加视觉复杂度。

6 自然语言形式化有进展也有双重正确性问题

把自然语言翻译为可执行模型，已形成较成熟的研究方向。NL4Opt 把语义实体和中间表示拆开；OptiMUS 用参数、变量、目标和约束的连接图维护局部上下文；DRoC 针对 48 种 VRP 拆分约束、检索相应知识再生成求解代码。它们共同提示：在固定求解器外做可靠建模，比要求模型自行完成全部搜索更可控。[N08][N09][N05]

但“语法正确、求解器给出了最优解”仍可能是解错了问题。Planning Formalizers 原文将 solvability 与 correctness 分开，发现自然表达比模板表达更困难，错误包括初始状态、动作关系和参数顺序。它属于规划域而非 VRP，不能拿其数字预测 VRP 成功率，却直接说明了为何应保留语义金标和来源链。[N06]

ARS 最贴近本项目的代码路线：先选择参考约束，生成 checker 和 scorer，再接入固定 destroy-repair/local-search 主干。主表中 48 项常见问题成功率 91.67%，RoutBench-H 为 46.80%；后者不能被摘要的较高数字覆盖。附录的其他多次运行设置也不能与主表无条件合并。其重点是广约束程序生成，不是证明所有专用求解器都被超越。[N04]

因此要分两道正确性关：第一道是“用户意思→TaskSpec”是否准确，第二道是“TaskSpec→解”是否满足数学约束。第二道可由确定性程序检查；第一道需要有来源的字段、人工标注测试集、反例和编辑预览。不能让同一个模型同时写约束和写唯一验收器，然后用二者自洽作为语义正确的证明。

建议建立中文需求用例库，覆盖省略、否定、单位变换、同义表达、时窗端点、先取后送、相同车辆、软硬优先级等。每个例子有人工 gold TaskSpec 以及故意修改一项约束后应当改变的结果。重点测漏约束、错单位和错误默认，而不只测 JSON 能否解析。

7 直接生成路线要作为真正的对照

直接路线应有独立的实验位置，既不能预先判它失败，也不能把它与调用求解器的 agent 混为一谈。输入同一份 TaskSpec 序列化文本，输出车辆与任务 ID 序列；不给外部解算器。任何格式修复、反馈重试、best-of-N 或经典局部修补都须另设变体并计成本。[N11][N12]

2025 年的 LLMCoSolver 用 SFT 及可行性与最优性奖励训练 7B 模型，说明专门训练能使直接解明显改善。更重要的是其强基线附录：CVRP 的平均 gap 为 4.53%，HGS 为-0.19%，都相对论文的参考解；约 11 秒的三索引 Gurobi 建模则为 35.09%。所以“胜过 Gurobi”不能改写成“胜过成熟 VRP 启发式”。这里的负 gap 也说明参考值不是数学最优证书。[N11]

2026 年 ConstraintBench 把 200 个任务分布在 10 个运筹域，单轮直接输出由确定性程序重算，报告最佳模型 65%可行、30.5%同时可行且距参考 0.1%以内。每域仅 20 例且单次运行，不能将这个比例套到当前项目；其最大价值是清晰的全样本分母和独立约束检查，而不是最新模型的永久排名。[N12]

同年的 NLCO 覆盖 43 类问题和不同规模，报告小实例可表现很强，随规模上升，可行性和质量下降，推理 token 却增加。这纠正了“LLM 完全不能直接规划”的绝对化说法，也提示不要只演示 10 个点的漂亮路线后宣称可扩展。它的大量任务仍是可控生成/抽样，尚不是对真实运营多车系统的完整验证。[N13]

本项目的 C 组应从小规模严格可验实例开始，逐渐增加任务数、车辆数和约束组合。设统一输出契约、全尝试分母和失败类别。若 C 组在小例已无质量或成本优势，就保留为研究对照；若某个小问题族确有优势，也只对该适用域给结论，不据此替换全局固定基线。

8 自动算法设计应比较搜索机制与真实成本

FunSearch、EoH 和 ReEvo 证明了一种重要机制：模型提出代码，程序执行给出反馈，搜索保留有效候选。FunSearch 强调可快速评价、反馈足够丰富、骨架中存在可隔离的可演化部分；EoH 同时演化语言思路和代码；ReEvo 把候选性能比较转成反思再指导生成。[N01][N02][N03]

这些论文不能只比较宣传中的调用数。FunSearch 报告约百万量级采样，EoH 的 BPP 实验报告 2000 次调用，ReEvo 限制 100 次启发式评价；它们的模型、任务接口、候选预算、原有代码、评价集和资源并

非统一重跑。由此能得出“值得研究更高效的搜索机制”，不能直接给本项目某框架节省几百倍的成本承诺。[N01][N02][N03]

科研上应优先选择小而清楚的可演化界面，例如候选插入排序、移除评分、邻域采样或搜索接受控制。让固定骨架负责可行性与资源限制，让生成模块只输出合法候选或评分。这样既减少危险的自由代码，也便于通过移除某个项、固定参数或替换成手工规则解释收益来源。

反思、进化和多 agent 本身不是成果。需要加入同预算的无反思生成、best-of-N、随机变异、简单参数搜索，以及同框架的人工作品。尤其当收益仅来自重复尝试或更长运行时，必须把它与真正更好的启发式区分。ReEvo 限制章节已经提醒，其低评价预算下的优势不必然扩展到很大的搜索预算。[N03]

MCTS-AHD、EoH-S 和 LLM4AD 提供了树搜索、互补集合与工程框架等扩展方向；本次未完整复现其实现，先作为候选，而非把框架数量变成贡献数量。AlphaEvolve 进一步放大到较大代码片段，但仍依靠用户提供的可执行评价器，其 Google 内部基础设施结果不构成低成本 VRP 产品的交付保证。[N24][N22][N25][N21]

9 新的 VRP 证据支持局部算子路线

VRPAgent 把生成任务收缩为 LNS 中的 remove 与 order 算子，保留正确性保护的主框架。论文在 500、1000 和 2000 客户、三个 VRP 家族上与 HGS、SISRs、LKH3 和 PyVRP 等比较；发现阶段用 64 个 500 客户训练实例、每例 20 秒，进行多个发现运行再用验证集选优。所谓单核运行指最终解算器，而不是整个发现过程没有模型或训练成本。[N17]

AILS-AHD 演化强 ILS 中的 ruin 启发式，并采用加速机制。2026 年 6 月版本的新 BKS 有 CVRPLib 官方登记交叉支持，比仅展示随机平面小例更有说服力。但新 BKS 是最好一次成绩，平均表现另有结论；原文大规模表中也存在不如 AILS-II 的实例。长时间搜索和公开基准上的反复开发，不能替代新的区域与问题家族测试。[N18][N26]

2026 年 CVRPLib BKS Challenge 的官方结果确认 OptVerse-CityU 第一。队伍注册报告描述 EoH 自动控制函数、AILS-II、NPU 并行搜索、共享精英池与高质量 warm-start 的组合，机构公告称持有 51/100 项

最终 BKS。它支持“LLM 生成组件能进入强系统并取得真实成绩”；因缺少同资源去除 LLM 组件的最终竞赛消融，不能把整场成绩单独归因给 LLM。[N26][N27][N28]

PyVRP+论文报告在多个变体中替换父代选择、存活选择及惩罚模块，最大质量改善 2.70%；其当前作者链接却仅有 README 占位。先列为待复现的预印本证据，不能拿它作首版产品依赖，更不能默认其收益对现行 PyVRP 版本仍成立。[N19]

本项目据此应提高 D1 局部算子路线的研究优先级，但不立即开大预算搜索。先做受限接口、强固定基线、隐藏测试和评价成本核算。优先争取“在指定预算与分布外条件下稳定改善一个明确算子”，比声称自动发明通用 VRP 求解器更可实现，也更容易形成可信论文。

10 算法选择与跑完整个算法池必须分开

算法池有互补性，和能够提前选对算法，是两个问题。EoH-S 的集合目标对每个实例取集合成员中的最好损失，它证明的是 best-of-set 潜力。部署时若运行全部成员才知道最好者，就应按组合求解计所有 CPU 时间；若只运行一个成员，就需要真正的选择器，并承受预测错误。[N22]

SBS 是训练或验证阶段选择的单一最好求解器，VBS 是事后知道每例最好成员的上界。选择器的价值应看它实际关闭多少 SBS 到 VBS 的差距，同时计算特征提取与选择延迟。VBS 与 SBS 非常接近时，复杂推荐器的可获取收益本来就小；即使能降低均值，也要看最坏家族的退化。[N23][N32]

LLM 增强算法表示是一条研究线：AS-LLM 从算法代码抽取表示，再与实例表示匹配，论文在 ASlib 情景评估。它不等于让聊天模型看到地图后主观选择算法，也没有直接证明本项目的 VRP 小池能从代码嵌入获益。先跑便宜的手工特征和简单分类/回归，才有理由增加复杂表示。[N23]

当前项目交接指出，5NN 与距离门控在跨家族评估中失败，保守 SBS 仍是合理默认；小固定池在同生成器新几何上的 0.688%改善只支持很窄的同分布结论。不可把新增几何样本称作全新的任务分布，也不能把非 LLM 池的收益署名给 LLM。

建议保留稳定 select_solver 接口，内部先返回固定基线。后续只有当冻结池的互补空间足够大、独立训练标签齐备、分布外测试实际超过 SBS 且拒绝/回退机制可靠时，再启用推荐。回退条件应基于经验证的适用域或缺失特征，不能仅凭一个看似合理的距离阈值就宣称安全。

11 数据应按真实几何和真实任务分别标注

建立四份来源账本：geometry、tasks、vehicles、travel_cost。官方地块边界加自造需求，只能称“真实几何＋合成任务”；历史车辆轨迹不等于任务分工标签；BKS 不等于最优性证明。选择数据时先判断要验证的环节，再问数据是否具备相应真值。

主实验应从 CVRPLIB X 与 Solomon/SINTEF 开始，以便复现容量、时窗和标准目标。CVRPLIB 不能全库一概叫合成：Uchoa 原报告明确 F 系列有真实运营来源，而 X 系列是设计生成。本次核验的 SINTEF Solomon 100 客户页采用车辆数优先、距离次之，并有明确数值口径；与单目标或不同精度口径的成绩不可直接比较，可能改变排名。[D13][D14][D25]

真实几何扩展可以取 PDOK BRP 或法国 IGN RPG 小区域；这是对地域和图形结构的外部测试。需求、车队、服务时长与时窗若由生成器产生，必须逐字段标记，公开种子、分布、容量紧度、可行率和构造方法。不要只用均匀随机点；加入聚类/混合、需求相关、窄时窗、断连与不规则边界，并按区域留出而不只换随机 seed。[D03][D06][D09]

真实运营旁证可选 Amazon Last Mile 公开数据：9184 条 2018 历史配送路线，位置经匿名扰动，许可为 CC-BY-NC4.0。其挑战是既定路线内的访问排序，不能任意合并路线再称“真实多车重分配最优解”。应保留 route_id 边界和给定时间矩阵，单列跨域评估。[D22][D23]

本轮没有核到开放且同时具备农业任务、完整车队、时间窗、服务时间、通行状态与实际执行轨迹的统一多车 VRP 集；这不证明其不存在。首版不应等到完美数据才开始，也不应以一个真实地图背景掩盖任务仍是合成的事实。

数据轨	可支持的结论	不能支持的结论
标准 VRP 基准	算法/约束和数值复现	真实农业运营有效
真实几何加合成任务	地理结构迁移与导入可靠性	需求和服务时间真实
历史真实路线	运营约束或排序旁证	重新分车已最优
田间轨迹或地块	定位/覆盖组件验证	完整多车调度已解决

12 地图来源和通行语义的关键风险

Fields2Benchmark 的 350 个真实地块适合 CPP 组件测试。本轮实际小量下载 WKT 包，文件数及发布者 MD5 一致；样本未附 CRS 侧车，不能因为坐标看起来像经纬度就当作已证 EPSG。顶层 LICENSE 为 CC-BY-SA4.0，作者落地页另列立陶宛来源“仅非商用”说明，必须保留逐来源权利边界。[D01][D02][D28]

PDOK 官方 BRP API 无需认证，存储坐标为 EPSG:28992，默认 GeoJSON 为 CRS84，当前许可显示 Public Domain Mark1.0。本次实取的一条 2025 定稿要素是沟渠，不是可作业田块，所以必须筛选地景类别。API 元数据里异常的 2006 更新时间不能当数据年份，要查 feature 年份或发布版本。[D03][D04][D05]

IGN RPG 只覆盖 PAC 申报范围；SNA 障碍资料也存在遗漏。BD TOPO 可以提供道路、水文和建筑骨架，但不能证明农机通行权、闸门状态或路面承载。EuroCrops v2 可扩展跨国跨年测试，须固定实际目录和版本，留意官方记录的重叠几何修复。Rosario v2 适合真实田间定位/轨迹回放，不提供多车订单真值。[D06][D07][D08][D09][D10][D11][D12]

RFC7946 GeoJSON 交换层采用 WGS84，经度、纬度顺序，单位为度；内部距离、缓冲和转弯计算用适当米制坐标，不能把度数直接做欧氏米距离。栅格要保存原点、分辨率、方向与像元中心规则；截图没有配准信息时只是示意。道路交叉还须核桥隧层级、单行与入口，地块质心不能自动当合法停车或进场点。[D15][D16][D19]

OSRM 矩阵中的距离是最快路线对应的距离，并非必然最短距离；不可达项和直线 fallback 必须显式处理。矩阵、路线路径、车型 profile 和地图快照应一起冻结。狭窄共享通道的时空冲突要另做 MAPF 或连续运动建模；地图线相交与否都不构成实车安全证明。[D20][D24]

13 成熟求解器应按固定版本选择

当前最小闭环建议 OR-Tools 9.15.6755、Python3.10 独立求解进程、独立 checker 与现有文件/SQLite 管理。官方元数据提供 Python≥3.9 和 Linux CPython3.10 wheel，较适合 Ubuntu22.04 原型；本轮未

安装，因此仍要做环境烟测。先支持单仓、同构、硬容量和必访静态任务，再逐项验收时窗、多仓与异构。[T01][T02][T03]

OR-Tools 的可塑性有代价：取送同车和先后等需要显式建模，不能只凭 API 名称猜含义；返回状态与搜索限额也应原样保留。它不提供真实道路数据，不能默认保证全局最优。不同求解器无法表达的约束记 unsupported，不能静默删去。[T02][T04]

PyVRP 适合后续强基线，但版本尤其重要。v0.14.0 源码已使用 IteratedLocalSearch，不能仍按 2024 论文将当前版本称为 HGS；需要 Python≥3.11。稳定源码有多仓、异构 profile/容量、时窗、shipment 和 reload 等入口，自动工时休息、公平性等则标为 Enterprise。主页 1.0.0a0 能力不能全部归给稳定免费版本。[T05][T06][T07]

VROOM 更接近道路配送 JSON 服务：容量、技能、班次/休息、时窗、shipment 和自定义矩阵较现成。v1.15.0 要求 C++20 且发行 CI 使用更新工具链，Ubuntu22.04 默认环境不算已验证开箱即用。返回 code=0 也可能有 unassigned；plan 模式会软化约束，其 violations 不是独立 checker。[T08][T09]

没有本项目同约束同预算测试，不能给这三者速度与质量总排名。建议以覆盖明确的 A0 为主，另外保留传统 HGS 固定实现和适当 PyVRP 版本作研究对照；把历史论文基线版本与拟实施新版本写清，避免版本升级悄悄改变结论。

候选	许可与环境	当前取舍
OR-Tools9.15	Apache2.0；Python≥3.9	首版通用建模骨架
PyVRP0.14	MIT；Python≥3.11；ILS	强基线候选；先测新 API
VROOM1.15	BSD2；C++20	道路配送集成备选

14 路由引擎与呈现层各司其职

小规模首版优先 TypeScript/SVG 米制地图；SVG 便于任务点点击、路线箭头和证据定位，密集格子再考虑 Canvas。真实路网分支可用 VROOM1.15.0＋OSRM26.10.0 固定区域快照＋Leaflet1.9.4。OSRM 的

route 按给定顺序寻路、table 产矩阵、trip 做途经点排序，均不能自动承担容量和时窗下的多车分工。[T10][T11][T16]

Valhalla 适合动态 costing 与路线/矩阵，但 optimized_route 是单路线排序；时间依赖矩阵也有模式和条件限制。GraphHopper 本地开源路由引擎与其商业 Matrix/Route Optimization 服务应分开，不能把托管优化能力当成本地安装已经拥有。[T12][T13][T14][T15]

地图层按需求选择：Leaflet 适合轻量 2D 和 GeoJSON；MapLibre 适合矢量瓦片与复杂分层，但不含底图、地理编码和求解；deck.gl 适合大规模点和轨迹展示，几十任务不必默认引入 GPU 复杂度；React Flow 适合流程节点，不天然带有米制距离或通行语义。手机采用地图/任务/结果切换，保留表格回退，后续再实际测试触控、弱网与 WebGL。[T16][T17][T18][T19]

成熟开源示例可借鉴交互，但不可直接当性能证据。VROOM 前端展示请求与地图配合；Google Fleet Routing App 展示表单、任务表与地图联动，官方定位为探索用途，即使本地运行仍可能产生 API 费用。此次没有启用计费或上传私人任务到公有 demo。[T20][T21]

离线必须同时本地化脚本、字体、瓦片和路网数据；仅网页文件本地并不等于系统离线。OSM 数据许可和客户端库许可独立，标准公共瓦片禁止离线批量下载。商业 API 套餐的车辆/地点数、credits、税与数据外发都可能限制实验；本轮不购买、不据展示价作预算承诺。[T22][T15]

层	推荐或候选	验收重点
编辑	SVG 优先；Canvas 按规模	真实单位、稳定 ID、改动使旧解失效
路网	固定 OSRM；Valhalla 备选	有向可达、车型 profile、无路不补直线
地图	Leaflet；MapLibre 按需求	来源/许可、坐标顺序、手机回退
科研结果	任务表＋路线＋时间轴	同输入对照、失败分母、可追溯日志

15 四路线的实验矩阵

主实验至少分两条输入轨：优化轨直接给所有组同一份人工 gold TaskSpec，隔离求解能力；端到端轨再加入自然语言解析和编辑成本，测系统总成功率。若把 A 组给正确结构化数据、C/D 组给模糊文本，却只比较终点成本，无法知道差异来自解析还是求解。

所有组使用同任务、同成本矩阵、同硬约束和目标顺序、相同可获得信息及预算规则。固定基线必须是适配正确的成熟求解器，简单最近邻仅作弱基线。对工具不支持的约束，记录不支持或另建共同子集，不能悄悄删掉约束让它参赛。

生成代码还应拆成 D0 与 D1。D0 只是生成调用同一固定后端的适配代码，测建模和接口；D1 在受信框架内产生新算子，才是算法设计。自由生成完整算法 D2 放后期探索。LLM 直接路线若调用了外部求解器，就已经不属于严格 C 组。

完整矩阵和拟议预算见 experiment_matrix.csv 及 research_protocol.json。它们是预注册草案，不是已经完成的实验。

主组	真实输出	关键比较
A 固定算法	冻结成熟求解器的路线	强基线；弱基线另外保留
B 算法选择	冻结池中的一个算法	SBS、VBS 及跑全池对照
C 直接路线	车辆对应任务 ID 序列	单次与有限反馈分开
D 生成代码	适配代码或受限算子	D0 接口正确性与 D1 设计收益分开

16 预算与分布外协议决定结论能否成立

先固定线上预算，再单列离线成本。建议 CPU 主轨取 1、10、60 秒几个档位，以烟测确认任务规模后预注册；不要让 LLM 组超时继续想、固定组却硬截断。LLM 线上时间从拿到完整输入算起，包含服务等待、重试、编译与运行；网络时间可额外拆分，但不能从端到端体验里消失。

离线成本含每次模型请求、输入输出 token、实际价格或套餐计量、候选生成/失败数量、所有评估 CPU 或 GPU 秒、人工调试以及验证集调参。已生成的算子部署时可能很便宜，但须报告用多少未来任务才能摊平发现投入。并行墙钟时间和总资源消耗分别给出，不能用更多核心掩盖成本。

测试至少分五层：同家族新 seed、未见规模、未见生成器家族、未见城市/路网、未见约束组合。由同一父实例缩放、旋转或重采样出来的兄弟样本要整组划分，避免一个进训练、另一个进测试。既要公开标准基准便于比较，也要保留真正未曝光的终测集。[N14][N16][N29]

初始方案可用每实例至少 5 个独立求解 seed 和多个代码发现 seed，但最终数量应按方差和预算确定。统计单位是独立实例，不是把同例的 5 次运行当 5 个全新任务。报告配对差异、按家族与实例分层的置信区间、最坏家族退化和预算性能曲线；预先规定主比较，避免跑完再挑胜出的档位。

主指标先报告全尝试可行率，再报告可行条件下 gap 和“可行且达到预定质量阈值”的联合成功率。API 失败、格式失败、超时和不可行都留在总分母里。不能只给成功样本平均路线长度。无最优证书时用 BKS-gap 或参照固定基线的相对差，并明确参考不是理论最优。

17 独立校验需要两层隔离和反例测试

运行隔离与逻辑独立是两回事。一个 checker 即使在单独进程里，如果复制了优化器的错误载重公式，仍可能共同出错。评价器应依据书面的任务合同独立实现，不能让候选程序修改，也不能把终测标签、参考目标和隐藏用例暴露给生成器。[N14][N15][N16]

校验顺序建议是：结构与 ID 合法 → 必做任务恰好服务一次 → 车辆资格与起终点 → 路网有向可达 → 载重沿路线变化 → 取送配对和先后 → 时间传播、等待和服务 → 时窗与班次 → 其余声明硬约束 → 独立重算目标。对选择性服务任务，必须按同一个惩罚或收益定义算目标，不能把未服务点抹掉。

同一个问题类型还需要校验器的测试。用极小实例枚举或可信精确模型建立答案；故意重复一个点、漏一个点、交换取送、跨容量、超时窗端点、使用不可达边，确保全部被拒绝。加入任务重命名/输入顺序打乱的等价性测试、零需求、同坐标、NaN/无穷大、负值和非常大的单位边界。

解可行并不能替代语义正确。端到端轨还应检查 TaskSpec 是否与人工 gold 约束一致；新增“必须同车”却没有改变模型，应直接判语义失败。对于真实道路，矩阵和显示路径来自同一图版本/车辆

profile；若地图更新，旧矩阵和旧路线不能混用。对于动态任务，保留当时可见信息，不能让算法提前看到未来订单。

模型之间交叉审阅可用来提出问题，但不能作为通过标准。最终接受由受信程序、数据来源核验和必要的人类语义审查决定。应保存每项校验结果、violations、输入 hash、解 hash、checker 版本和重算目标，以便未来换模型或求解器时仍能追溯同一事实。

18 失败状态与生成代码的安全边界

系统要准确区分四种状态：输入不足或歧义、求解器不支持、预算内未找到可行解、已证明不可行。启发式超时不代表问题数学上无解；“无解”与“没找到”混写会误导用户的业务决策。若确有证明，保留证明/solver 状态；若只能分析冲突，给出可能相关的约束而不冒充最小不可满足集合。

可视化必须把未分配任务、失败车辆和违反约束显示出来。用户可以调整任务或预算重新运行，但系统不得擅自把硬约束降成软约束以便画出一张完整图。若实验专门研究松弛，应另设场景并清楚展示松弛量与代价。

LLM 生成代码按不可信程序处理：无网络、无凭证、只读实例、可写临时输出、CPU/内存/进程数/墙钟限额；禁止读取隐藏参考、访问其他实验目录、动态安装包和修改计时器或 checker。候选代码、依赖白名单与最终冻结 hash 必须记录。正常的语法/运行错误可以在同一授权预算里修复；越权请求不能通过换工具绕开。[N16]

任务文本、地图属性和文件内容也可能包含与求解无关的指令。将其视为数据，结构化提取只接受白名单字段，禁止把原始文本直接插入 shell。控制界面中每一次外部动作都应与研究任务分离，防止论文示例代码或网页 README 指令自动触发付费调用、账户操作和部署。

本次阶段仅做调研与交付，不启动新的付费调用、新 API 密钥或部署。后续科研实验继续沿已授权账号与受限数据范围执行；源码、结果、日志和许可证清单分别保留，避免把密钥和无关文件带入科研归档。

19 项目内新证据怎样影响架构

最新 CVRP 规模扩展在 16 个同生成器新几何上完成 384 条轨迹与 768 个检查点。160000 delta 预算下，预定 random_regret2 对 random_cheapest 的配对改善 0.3575%，几何块 bootstrap 95%区间为 0.2737%至 0.4524%。但 n200 在 40000 预算时四法都未改善初始化，160000 时 random_regret2 仍有 21/48 条未完成一轮。这支持预算校准，不支持“规模性能充分”或 LLM 价值。[P01]

几何组件实验提供了另一条重要证据：24 个合成底图、固定 7 个服务位姿、三个转弯半径共 72 例，欧氏顺序后补 Dubins 连接有 65 例可行，直接优化可行候选图有 67 例可行；共同 65 例前者平均长 18.94%。这提示车辆几何若改变边代价与可行性，应在排序前进入模型，不能事后只把折线画圆滑。[P02]

图中的红虚线是越出边界的候选，不是可接受路线。这里的最优/无解只针对六类 Dubins 连接候选组成的有限图，五例无 tour 不等于连续物理空间全局无路。本实验没有多车分配、容量、车身碰撞、加速度或转向速率；可以支撑组件设计，不能升级为农机实车效果。[P02]

本轮调研读取了现成报告和此图，没有重跑这些试验或独立复核全部原始数据。统计单位、数据和预算口径均沿用原报告；后续集成到 VRP 前，仍需重新验证多车约束与路径成本接口。

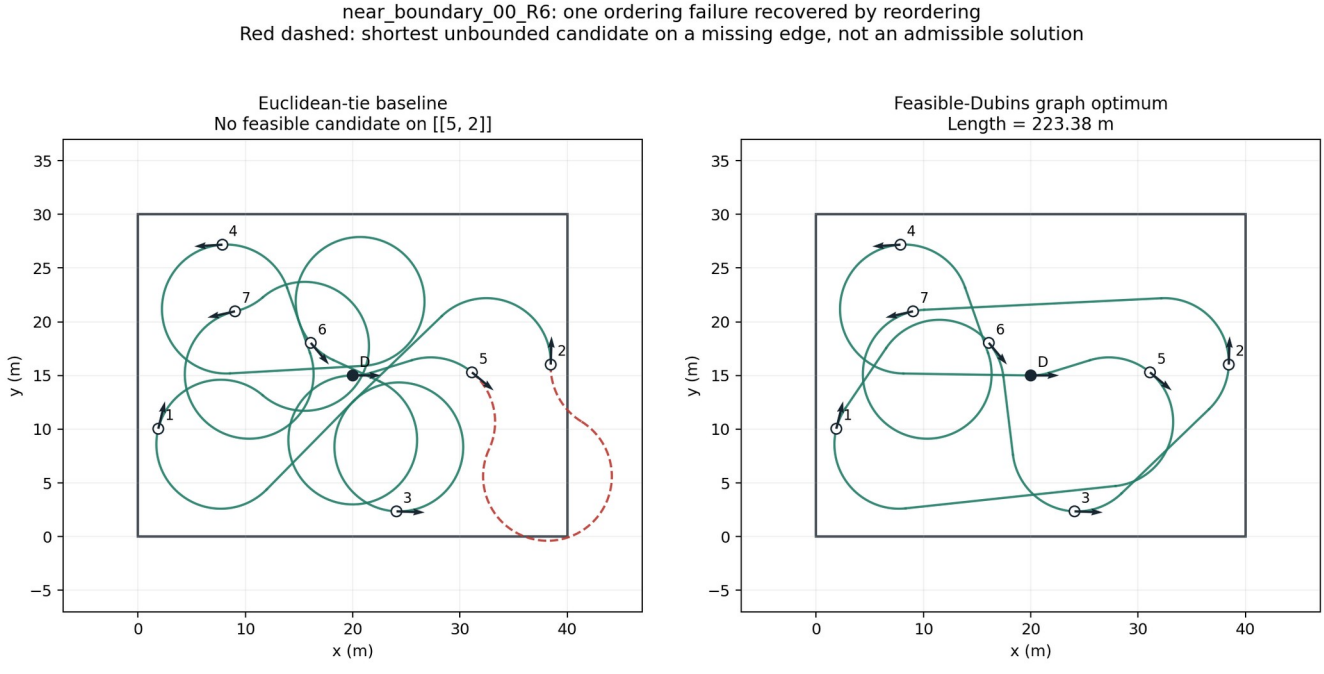


图 1 项目内合成几何组件实例 固定服务位姿及 R 等于 6 米 左为欧氏排序后的连接失败 右为有限可行 Dubins 图中的最优顺序 非真实地图和实车实验

20 分阶段落地和明确停止条件

第一阶段先把问题合同和固定闭环做对。选定点任务 CVRP 及一个明确扩展，如静态时窗；准备人工核验的小例、标准基准与失败反例。用可编辑地图、任务表和固定求解器完成“改一项→重算→独立验证→导出”的闭环。通过条件是所有声明约束都进入 schema、适配器、checker 和界面，不能只有 happy path。

第二阶段冻结研究底座。确定强基线和版本、数据分割、计时计费、随机种子、失败分类、源码与结果 hash。先跑无 LLM 的小规模烟测确认指标与边界，再允许四组正式比较。没有可用独立 checker 或无法隔离终测时，停止扩大样本，不用更多模型调用掩盖协议缺陷。

第三阶段测自然语言接口。构建人工 gold 中文任务规格与语义扰动集，比较模板抽取、LLM 结构化输出和检索辅助。收益看完整约束提取、错误默认率、编辑次数和端到端成功率。若只是句子更漂亮而没有减少错误或操作成本，不算系统贡献。

第四阶段做局部算法设计。优先一个接口和一个主问题族，先比较固定专家算子、无反思生成、随机/参数搜索及 EoH/ReEvo 类搜索。只有在隐藏测试集、多个发现 seed 及完整成本下出现稳定实用收益，才扩展更多家族或更自由代码。失败结论同样保留，避免从几十条候选中只讲幸运的一条。

选择器采用独立闸门：互补空间足够、实际选择超过 SBS、尾部可控、拒绝回退有真实证据，四项都满足才进入默认链。若未通过，保持 SBS 不影响产品首版完成。3D 演示、机器人避碰、实时重规划和复杂农业覆盖均在前述闭环稳定以后单独立项。

对本科项目，最可信的论文主线可定为“自然语言驱动的可编辑多车任务建模与独立验证平台”，再用四路线公平实验回答 LLM 在哪个环节有可测价值。若 D1 真正产生新收益，再把论文重心提升为受约束自动启发式设计；不能在结果出现前先把故事写成 LLM 全面超越传统方法。

21 当前项目证据边界与交付清单

本报告继承的项目状态是：六项 CPU 研究和独立审计支持保守 SBS，5NN 及距离门控没有通过跨家族验证；CVRP 小固定池在同生成器新几何上观察到 0.688%改善。它没有证明 LLM 价值、没有证明真实道路收益，也不能代表跨家族泛化。本次没有重新审计这六项原始运行，相关数字只作为已交接约束。

原 BPP132 主线仍未启动新的模型调用。36 模型×档位筛选已结束并归档，但它属于文本装箱代码生成的小样本筛选，不是多模态地图或 VRP 证据，不能据此选 VRP 模型赢家。BPP 到 CVRP 是任务迁移，聊天或编程筛选到 VRP 可行性也是任务迁移。使用已冻结父代源码有助于可重复性，但不免除新的问题合同和测试。

本轮交付包含中文可编辑报告、PDF 阅读版、来源 CSV/JSON、四路线实验矩阵、机器可读研究协议与任务合同草案。来源表逐条记录实际阅读深度、代码发布状态和局限；报告中的外部性能数字均是原作者或官方记录，不冒称本项目重跑结果。

实施前的最后检查是：任务到底是什么、数据哪里来、哪些是假设、哪个版本在解、每个硬约束怎样验、失败怎样显示、预算怎样算、终测有没有泄漏、能否复现同一张图与同一条指标。如果这九项没有答案，继续加模型和 3D 效果只会增加难以定位的错误。

最终建议保持不变：先完成可靠的可编辑固定求解闭环，再用公平实验决定 LLM 和推荐器应进入哪里。这样的系统即使某条研究假设被证伪，仍然有实际可用的成果；一旦生成算子确有收益，也能在同一证据链上被清楚验证。

来源索引与阅读审计

本轮合并 83 组外部证据记录及 2 项项目报告，共 85 组，包含论文、官方数据、代码、文档和登记记录，不等于 85 篇论文。83 个主入口及其支持链接去重后共 135 个 URL。未统计搜索引擎全部命中，不能视为穷尽检索。逐条阅读范围、代码状态、限制及访问日期见 sources_all.csv。以下编号与正文引用一致。

[N01] Mathematical discoveries from program search with large language models (2024)。原文定点核读。 原始来源 官方源码/已生成启发式可见；原模型、沙箱和分布式设施不在发布中；本次未运行

[N02] Evolution of Heuristics (2024)。原文定点核读。 原始来源

[N03] ReEvo Large Language Models as Hyper Heuristics with Reflective Evolution (2024)。原文定点核读。 原始来源

[N04] ARS Automatic Routing Solver with Large Language Models (2025)。原文定点核读。 原始来源

[N05] DRoC Elevating Large Language Models for Complex Vehicle Routing via Decomposed Retrieval of Constraints (2025)。摘要及官方文档。 原始来源

[N06] On the Limit of Language Models as Planning Formalizers (2025)。原文定点核读。 原始来源

[N07] LLMs Cannot Plan But Can Help Planning in LLM Modulo Frameworks (2024)。原文定点核读。 原始来源

[N08] NL4Opt Competition Formulating Optimization Problems Based on Their Natural Language Descriptions (2023)。原文定点核读。 原始来源

[N09] OptiMUS Scalable Optimization Modeling with MILP Solvers and Large Language Models (2024)。原文定点核读。 原始来源

[N10] OptiBench Meets ReSocratic Measure and Improve LLMs for Optimization Modeling (2025)。摘要及官方文档。 原始来源

[N11] Large Language Models as End to end Combinatorial Optimization Solvers (2025)。原文定点核读。 原始来源

[N12] ConstraintBench Benchmarking LLM Constraint Reasoning on Direct Optimization (2026)。原文定点核读。 原始来源

[N13] Reasoning in a Combinatorial and Constrained World Benchmarking LLMs on Natural Language Combinatorial Optimization (2026)。原文定点核读。 原始来源

[N14] CO Bench Benchmarking Language Model Agents in Algorithm Search for Combinatorial Optimization (2026)。原文定点核读。 原始来源

[N15] HeuriGym An Agentic Benchmark for LLM Crafted Heuristics in Combinatorial Optimization (2026)。原文定点核读。 原始来源

[N16] FrontierOR Benchmarking LLM Capacity for Efficient Algorithm Design in Large Scale Optimization (2026)。原文定点核读及官方文档。 原始来源

[N17] VRPAgent LLM Driven Discovery of Heuristic Operators for Vehicle Routing Problems (2025)。原文定点核读。 原始来源 官方仅 early release 生成启发式/样例种群；未见完整发现与评测管线；未运行

[N18] Enhancing CVRP Solver through LLM driven Automatic Heuristic Design (2026)。原文定点核读。 原始来源

[N19] PyVRP Plus LLM Driven Metacognitive Heuristic Evolution (2026)。原文定点核读。 原始来源 2026-10-07 查看仅 README 占位与 1 次提交；不是可复现完整实现

[N20] G LNS Generative Large Neighborhood Search for LLM Based Automatic Heuristic Design (2026)。原文概览。 原始来源

[N21] AlphaEvolve A coding agent for scientific and algorithmic discovery (2025)。原文概览。 原始来源

[N22] EoH S Evolution of Heuristic Set Using LLMs for Automated Heuristic Design (2026)。原文定点核读。 原始来源

[N23] Large Language Model Enhanced Algorithm Selection Towards Comprehensive Algorithm Representation (2024)。原文定点核读。 原始来源

[N24] Monte Carlo Tree Search for Comprehensive Exploration in LLM Based Automatic Heuristic Design (2025)。摘要。 原始来源

[N25] LLM4AD A Platform for Algorithm Design with Large Language Model (2025)。官方文档。 原始来源

[N26] CVRPLib Official Updates and Verified BKS Challenge Results (2026)。官方记录。 原始来源

[N27] AILS II Enhanced Automated Control Discovery via LLMs and NPU Accelerated Cooperative Search (2026)。原文定点核读。 原始来源

[N28] CityU Optima Group Competition Announcement (2026)。官方公告。 原始来源

[N29] Search Time Data Contamination (2025)。摘要及作者研究页。 原始来源

[N30] Vehicle Routing Problem Meets Large Language Models An Overview and Perspectives (2026)。原文定点核读。 原始来源

[N31] From Words to Routes Applying Large Language Models to Vehicle Routing (2024)。作者项目文档。 原始来源

[N32] ASlib Algorithm Selection Library (2016)。官方文档。 原始来源

[D01] Fields2Benchmark author dataset landing page。落地页说明、逐国许可、文件清单已读；WKT 包实际下载审计。 原始来源

[D02] Fields2Benchmark LICENSE。打开许可文本并检查名称、适用范围条款。 原始来源

[D03] PDOK BRP introduction。正文及服务入口已读。 原始来源

[D04] PDOK BRP OGC API landing and collections。API 入口与完整 collections JSON 已读。 原始来源

[D05] PDOK BRP one-feature actual response。实际 GET HTTP200；1426 字节保存并 SHA256。 原始来源

[D06] IGN RPG official government catalogue。说明、覆盖、边界条件、许可、文档链接已读。 原始来源

[D07] IGN RPG v3.0 content and delivery specification。56 页 PDF 选择性读第 7、50、51 页 CRS 及交付章节。 原始来源

[D08] IGN BD TOPO official catalogue。版本、主题、更新、许可、服务链接已读。 原始来源

[D09] EuroCrops v2.0 original article。全文网页定向精读摘要、数据和限制部分。 原始来源

[D10] JRC EuroCropsV2 data README/index。README、schema、CRS 与版本历史已读。 原始来源

[D11] JRC EuroCropsV2 copyright。11 行许可全文已读。 原始来源

[D12] Rosario v2 author project site。序列、坐标、ground-truth、修正、许可与下载入口已读。 原始来源

[D13] CVRPLIB official instances。实例目录及集合标签已读。 原始来源

[D14] SINTEF Solomon 100-customer benchmark。实例说明、目标/精度、下载入口和 BKS 表已读。 原始来源

[D15] RFC 7946 GeoJSON。第 3.1.1、3.1.10、4 节定向精读。 原始来源

[D16] GDAL Geotransform Tutorial。教程全文已读。 原始来源

[D17] Fields2Cover basic types。车辆参数、几何类型部分已读。 原始来源

[D18] Fields2Cover objective functions。distance with/without turns 段落已读。 原始来源

[D19] Moving AI grid/scenario format。格式页全文已读。 原始来源

[D20] OSRM API v5.24.0。Route、Table、fallback 和返回值定向精读。 原始来源

[D21] OpenStreetMap Copyright and License。版权页及 contributors disclaimer 已读。 原始来源

[D22] Amazon Last Mile official open-data registry。规模、年份、匿名化、许可、获取说明已读。 原始来源

[D23] Amazon challenge data structures。Data Field Definitions 与 JSON 格式已读。 原始来源

[D24] Stern et al. MAPF definitions/variants/benchmarks。8 页 PDF 定向精读第 1–4 页定义/冲突/运动学；其余浏览。 原始来源

[D25] Uchoa et al. CVRP new benchmark original report。摘要及生成设计相关章节定向阅读。 原始来源

[D26] USDA NAIP official metadata。采样、时效、下载和 license 字段已读。 原始来源

[D27] Agricultural GNSS repository lead。README/根目录已查看，未读 rar 或运行。 原始来源

[D28] Fields2Benchmark publication at WUR。机构摘要和出版信息已读；PDF/出版社打开失败。 原始来源

[D29] Fields2Cover complete flow。教程全文已读。 原始来源

[T01] OR-Tools 功能与模型边界。官方文档及指定源码。 原始来源

[T02] OR-Tools v9.15 源码接口。官方文档及指定源码。 原始来源

[T03] OR-Tools 平台与许可。官方文档及指定源码。 原始来源

[T04] OR-Tools 状态。官方文档及指定源码。 原始来源

[T05] PyVRP 固定稳定版能力。官方文档及指定源码。 原始来源

[T06] PyVRP 算法与环境。官方文档及指定源码。 原始来源

[T07] PyVRP 在线文档版本陷阱。官方文档及指定源码。 原始来源

[T08] VROOM 稳定版 API 与许可。官方文档及指定源码。 原始来源

[T09] VROOM 构建与源码阅读范围。官方文档及指定源码。 原始来源

[T10] OSRM 当前稳定 API 与发行。官方文档及指定源码。 原始来源

[T11] OSRM 构建、离线与许可。官方文档及指定源码。 原始来源

[T12] Valhalla 路径/矩阵/排序。官方文档及指定源码。 原始来源

[T13] Valhalla 许可/部署。官方文档及指定源码。 原始来源

[T14] GraphHopper 本地引擎与商业优化的区别。官方文档及指定源码。 原始来源

[T15] GraphHopper 托管能力与成本。官方文档及指定源码。 原始来源

[T16] Leaflet。官方文档及指定源码。 原始来源

[T17] MapLibre GL JS。官方文档及指定源码。 原始来源

[T18] deck.gl。官方文档及指定源码。 原始来源

[T19] React Flow。官方文档及指定源码。 原始来源

[T20] VROOM 端到端演示。官方文档及指定源码。 原始来源

[T21] Google Fleet Routing App。官方文档及指定源码。 原始来源

[T22] OSM 数据许可与标准瓦片限制。官方文档及指定源码。 原始来源

[P01] 本项目 CVRP 规模扩展 n100 和 n200 (2026)。项目报告与现成图读取。 项目归档报告 CVRP_SCALE_REPORT_ZH.md

[P02] 本项目固定航向 Dubins 几何组件验证 (2026)。项目报告与现成图读取。 项目归档报告 CURVATURE_CONCLUSIONS_ZH.txt