固定候选档案的分簇与选父回放

论文机制组件实验 / 2026年10月6日 / 零新增模型调用与候选执行

结论：这批档案里的源码多样性明显高估了行为多样性。分簇抽样能保留更多行为，但也会选入当前质量更差的父代；本实验没有生成后代，不能据此宣称搜索效果提升。

本次把 FunSearch 的“ 按多输入分数签名分簇、优先较好簇、簇内偏向短程序 ”落实为独立可重跑组件。只读取两批已终态候选及45份既有评分，不改动正在运行的60槽生成协议，也不读取留出集。

一 档案究竟有多少种行为

批次	有效槽 / 原生成槽	不同源码	用箱签名	完整轨迹签名
phase0	4 / 12	3	1	1
followon	5 / 6	5	3	3
事后合并	9 / 18	8	3	3

phase0 的4份有效提交中有两份源码完全相同；其余不同源码在5个设计输入上的完整分配轨迹也都与 Best Fit（BF）一致。followon 的5份源码包含3份BF等价候选和2份更差候选。这里的等价只指这5个输入，轨迹通过已归档的逐输入 assignment SHA-256 对齐。

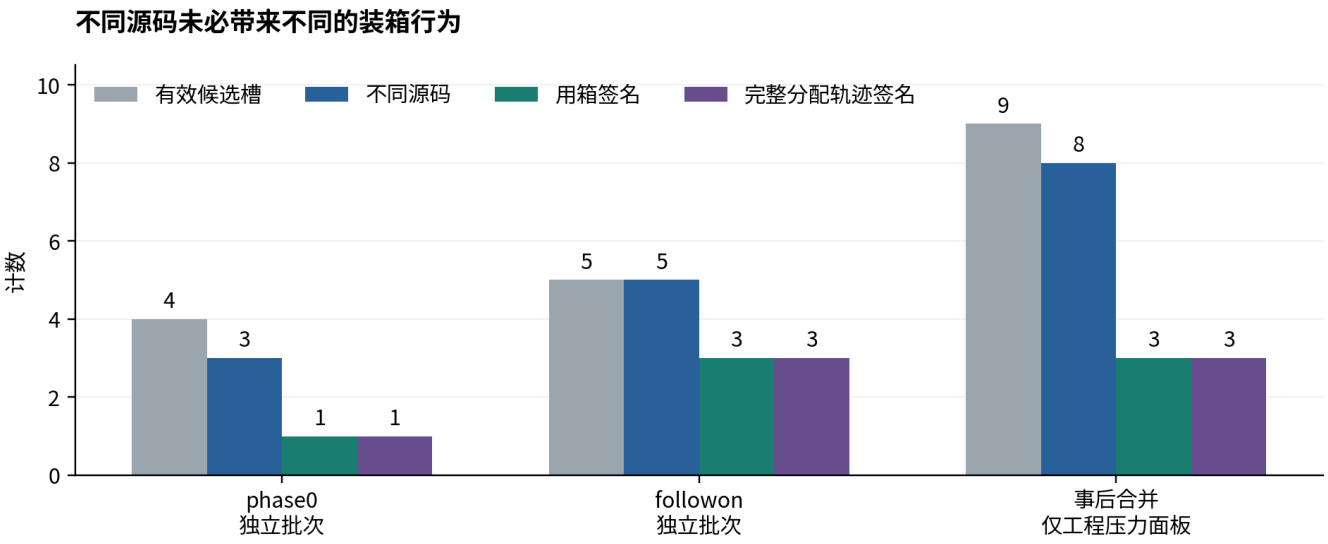


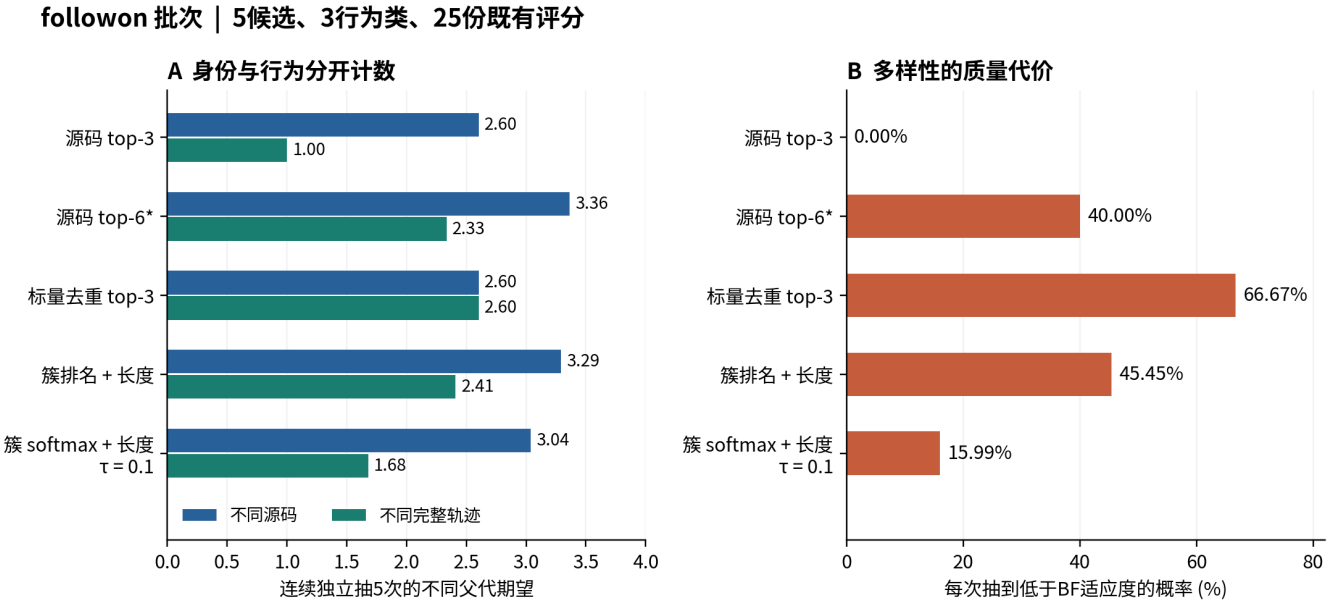
图1 行为用两个层级核对：5维用箱数元组，以及5条完整分配轨迹的哈希元组。事后合并仅用于工程压力测试；phase0 内两个原始生成臂也只在本组件回放中汇总，不做原始臂间效果比较。

二 followon 的父代分布发生了什么变化

每行描述固定分布下连续独立、有放回抽取5次父代。源码 top-k 和标量去重 top-k 保留后均匀抽样，是本实验对照，不是原版 EoH 的选父复现。簇方法使用整个源码去重档案，k=3/6 不作用于它们。

选父方法	BF概率	5次不同源码期望	5次不同轨迹期望	5次至少1个更差父代
源码 top-3	100.00%	2.605	1.000	0.00%
源码 top-6	60.00%	3.362	2.334	92.22%
标量去重 top-3/6	33.33%	2.605	2.605	99.59%
簇排名 + 长度	54.55%	3.292	2.410	95.17%
簇 softmax + 长度	84.01%	3.036	1.679	58.16%

top-6 在followon中只有5份源码可保留。标量去重只有3个不同精确适应度，所以k=3和k=6相同；本档案中标量适应度类与用箱签名类一一对应，无法用它证明多维签名优于标量去重。



* top-6 因档案只有5份源码而保留全部5份。簇方法使用全部去重档案，没有 top-k 截断。

图2 更差指平均适应度 mean(L1 / 用箱数) 低于BF；这两个更差候选也在全部5个输入上用了更多箱子。softmax主设置 τ =0.1：单次抽到更差父代15.99%，5次至少抽到一次为58.16%；选中父代的平均相对多用箱数为5.16%。这些是选父分布描述，不是后代性能。

三 phase0 与合并面板的边界

phase0 无论使用哪种已测选父方法，5次抽取的不同轨迹期望都为1；任何抽样法都不能凭空创造档案没有的行为。源码top-3的不同源码期望为2.605，加入长度偏置后为2.503。

合并工程面板中，源码top-3与top-6都只保留BF行为，尽管top-6可保留6份不同源码。全档案分簇的行为概率与followon相同，簇内源码分布有所改变。详细42组结果与每个父代概率均在附带CSV中。

四 怎样将论文机制变成可核查实验

来源是 FunSearch 论文 Methods 的 Evolutionary method and program selection，以及官方提交 cc53f274237d7ab05c19df939edbc1f9616a7c19 的 programs_database.py 和 config.py。论文支持先按多输入签名聚类，再按质量选簇、偏向短程序。官方代码的簇内长度公式为 exp(-(L-min L)/(max L+10^-6))，温度为1。

本实验明确采用适配：质量用URP的5输入精确 mean(L1 / bins)，不使用官方代码的“ 最后一个测试分数 ”；先做精确源码去重，以输入ID和哈希绑定签名；簇温度固定，不运行岛屿、重置或生成。官方初温0.1和周期30000只是来源依据；这里的 τ =0.1并不构成原版超参数复现。5次抽取是诊断窗口，原版默认每个提示2个程序。

主簇对照分别使用“ 质量排名的倒数 ”与 softmax(quality / τ) 作为簇权重。前者是新增秩权变体，后者是 FunSearch 式适配；两者簇内都采用短程序偏置。另测均匀簇、均匀簇内、保留重复槽和5个固定温度。

温度决定质量与行为多样性的权衡

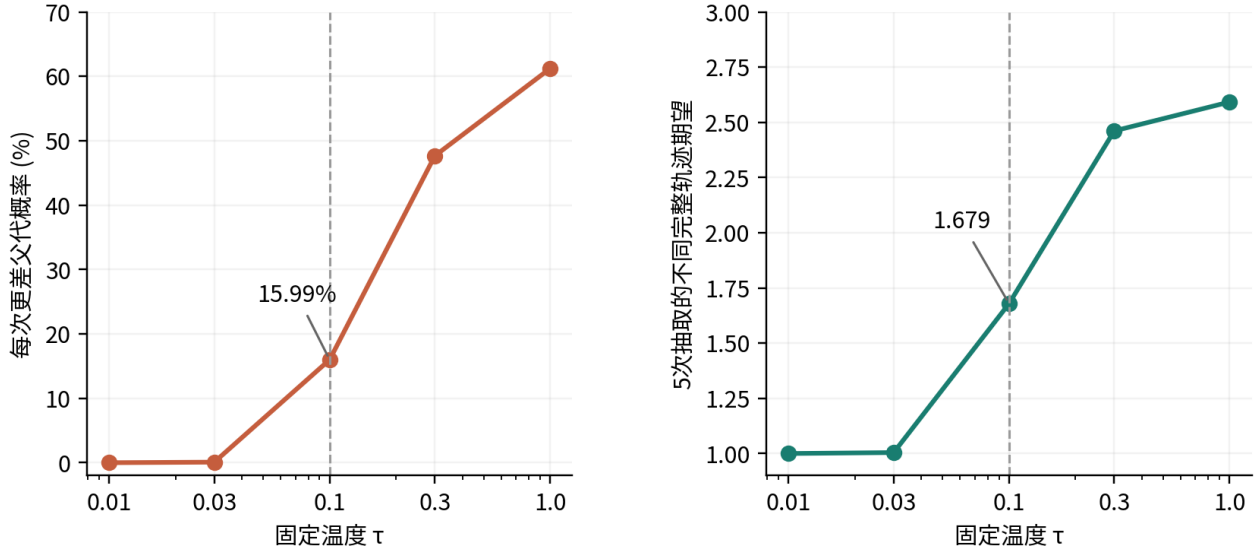


图3 温度敏感性使用事前冻结的0.01、0.03、0.1、0.3、1.0。 τ =0.03时单次更差概率约0.086%， τ =1时为61.23%。不能在看完结果后把最有利温度冒充预先确定的胜出参数。

五 复核与可重跑性

方案、13份输入副本的清单以及执行代码在04:14:22 UTC冻结。由于历史结果在冻结前已被检查，这是事后机制回放的运行前冻结，不是原始生成试验的前瞻性预注册。源码哈希、共同输入哈希、原始绑定和45份评分分母均经核对。

42个分布/批次组合共穷举401269个五次抽取的有序结果；与占有期望公式的最大绝对误差为2.23×10^-15。原始档案独立复算的6个followon主方法最大误差1.12×10^-16；另一次独立数学复核为1.34×10^-15。二次完整回放输出逐字节相同。

验证范围是已有证据、概率和多样性计算。没有重新执行45份候选评分，没有重新检验原隔离沙箱，也没有独立重算完整原始轨迹字节。小档案的精确计算不带来总体显著性或泛化结论。

六 可以推进的下一步

适合进入后续正式方案的是三层记录：源码身份、多输入成绩签名、完整轨迹签名。选父时同时报告行为占有期望和质量损失，避免用更多代码版本代替更多搜索方向。

还不能决定的是：保留这两个较差行为是否会成为有用的后代“ 踏脚石 ”。只有在另行冻结的后代生成实验中，用配对预算、固定选父法与评估协议比较后代改善率，才能回答。此次不启动该实验，也不修改正在运行的生成协议。

复现入口

解压完整实验包，在目录内运行 python replay.py --output rerun。数值回放只依赖Python标准库；输出RESULTS.json、selection_metrics.csv、parent_probabilities.csv和穷举校验记录。运行 make_figures.py 可重建科研图；需要Matplotlib与Noto CJK字体。运行 make_report.py 可重建本报告；需要ReportLab与Pillow。

原始输入位于raw；INPUT_MANIFEST.json记录来源路径与SHA-256；FREEZE.json固定运行前方案与执行代码。validation/INDEPENDENT_REVIEW.json和parent_review/math_review.json给出两份独立复核。完整结果保留top-k边界同分选择的全部组合，避免隐藏随机破同分的影响。

关键概念的口径

名称	本实验定义
源码身份	原始UTF-8代码字节的SHA-256；AST身份只作辅助描述
用箱签名	同一组5个输入按instance_index排序的用箱数元组
完整轨迹签名	同一顺序的5个assignment_sha256元组；依赖已归档评分证据
BF类	5个输入的完整分配轨迹哈希逐一等于独立BF控制
更差父代	精确平均L1/用箱数小于BF；此档案两例也均在每个输入更差
不同父代期望	对每类概率q计算sum[1-(1-q)^5]；按源码与轨迹分别汇总
有效多样性	1 / sum(q^2)；逐类概率平方和的倒数，详见CSV

参考来源

Romera-Paredes等，Mathematical discoveries from program search with large language models，Nature 625，468-475，2024。论文 DOI。

Google DeepMind FunSearch 官方 programs_database.py，固定提交 cc53f274。

Google DeepMind FunSearch 官方 config.py，同一固定提交。

原始实验数据：phase0终态数值档案、glm53_fixed_design_followon终态档案、frozen_design_controls的BF设计集控制；精确文件和哈希见实验包清单。