基于深度强化学习的收割机省内协同调度优化策略

李子康[1]，张 瑾[1,2※]，滕桂法[1,2,3]，李 政[1]，王梓怡[1]，马世纪[1]
（1. 河北农业大学信息科学与技术学院，保定 071001；2. 河北省农业大数据重点实验室，保定 071000；
3. 河北省数字农业产业技术研究院，石家庄 050000）

摘 要：针对目前多机多地块间调度作业存在效率低、成本高等问题，该研究构建了以收割机地块间转移成本最小为目标的协同调度模型，设计了基于深度强化学习的收割机协同调度优化算法 (inter-regional collaborative optimization scheduling algorithm based on deep reinforcement learning，DRL-ICOSA)。首先分析收割机调度作业的马尔可夫决策过程，构建基于注意力机制的策略网络和价值网络，在随机采样策略中引入动态高斯噪声，以避免训练初期陷入局部最优，同时提高网络模型的鲁棒性；接着采用近端策略优化算法 (proximal policy optimization,PPO) 训练网络模型；最后利用测试集验证 DRL-ICOSA 算法，得到收割机优化调度方案。基于有效作业时长 40 和 24 h、农机调度中心位于作业区域中心和区域边缘的 4 种组合作业场景下，采用 DRL-ICOSA 算法、遗传算法 (genetic algorithm，GA)、粒子群算法 (particle swarm optimization，PSO) 和模拟退火算法 (simulated annealing，SA) 计算调度策略并进行对比分析。试验结果表明：当调度中心位于区域中心或边缘时，有效作业时长为 40 h，DRL-ICOSA 算法相较于 GA、PSO 和 SA 算法，平均调度成本降幅不少于 13.9%；有效作业时长为 24 h，平均调度成本降幅不少于 11.5%。当作业时长为 40 或 24 h 时，调度中心位于区域中心，DRL-ICOSA 算法相较于 GA、PSO 和 SA 算法，平均调度成本降幅不少于 12.3%；调度中心位于区域边缘时，DRL-ICOSA 算法相较于 GA、PSO 和 SA 算法，平均调度降幅不低于 11.5%。因此，有效作业时长为 40 或 24 h、调度中心位于区域中心或边缘时，相比其他 3 种算法，DRL-ICOSA 算法均能计算得到最低的调度成本。这一研究结果可为收割机省内协同作业提供科学合理的调度方案。

关键词：农业机械；优化算法；路径规划；深度强化学习；协同调度
doi：10.11975/j.issn.1002-6819.202401145
中图分类号：S231 **文献标志码**：A **文章编号**：1002-6819(2024)-14-0023-10

李子康，张瑾，滕桂法，等. 基于深度强化学习的收割机省内协同调度优化策略[J]. **农业工程学报**，2024，40(14)：23-32. doi: 10.11975/j.issn.1002-6819.202401145 http://www.tcsae.org
LI Zikang, ZHANG Fan, TENG Guifa, et al. Deep reinforcement learning-based optimization strategy for the cooperative scheduling of harvesters[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(14): 23-32. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202401145 http://www.tcsae.org

0 引 言

农机调度作业作为农机社会化服务的一种创新模式，已广泛在省内同一县域或相邻不同县域间展开常态化调度作业。由于同省份内农作物普遍具有相近的成熟周期，在作业高峰期间会引发对农机的集中需求，常常形成“有机户有机没活干、无机户有活没机干”供需失衡的局面。由于缺乏科学合理的农机调度策略，使得作业效率受到严重制约，作业成本也相应攀升[1]。为促进农业增效、农民增收，研究收割机协同调度优化策略具有重要的实用价值。目前研究多采用传统启发式算法求解收割机作业调度优化问题，张帆等[2]建立了基于时间窗农机作业调度数学模型，提出改进多父辈遗传算法的模型求解方法。黄凰等[3]构建多农机站及时响应数学模型，提出保留优秀父代基因的改进遗传算法。张璠等[4]针对复杂灾害情景，建立了紧急调配模型，根据任务选择相应的紧急调度算法。ZHANG 等[5]提出了基于改进蚁群算法和 3 个突算变子的求解策略。HUANG 等[6]建立了多区域农业机械调度模型，通过改进粒子群优化算法完成对调度问题的求解。杨昊天等[7]提出最短距离优先的分布式算法，构建基于区块链的农机跨区域调度系统。曹光乔等[8]建立以最小调度成本为目标的农机跨区域调度模型，提出基于遗传变邻域搜索求解方法。尽管上述研究在解决收割机调度问题方面提供了可行解法，但仍未能摆脱传统优化算法求解结果质量低的局限。

随着人工智能技术的飞速发展，深度强化学习[9]因其强大的学习能力和优化决策能力，已经广泛应用于求解组合优化问题，为解决具有共同特征的车辆调度问题提供了一种新的思路[10]。MA 等[11]将图神经网络 GNN[12]与指针网络 (pointer network，PN) 结合提出图指针网络 (graph pointer network，GPN)，利用 GNN 提取节点特征，使用 PN 构建解，为大规模的旅行商问题 (traveling salesman problem，TSP) 提供了求解思路。KOOL 等[13]提出一种改进的 Transformer 模型，编码器采用多头注意

收稿日期：2024-01-18 修订日期：2024-05-06
基金项目：河北省重点研发项目（21327407D）；河北省高等学校科学研究项目（QN2023062）；河北省自然科学基金项目（C2023204069）
作者简介：李子康，研究方向为农机作业路径规划。
Email：860852120@qq.com
※通信作者：张瑾，博士，副教授，研究方向为智能调度作业与应用。
Email：ellenzhang0911@126.com

力机制 (multi-head attention，MHA)[14]，在解码过程中考虑第一步和近两步的决策，并利用带有基准的策略梯度 REINFORCE[15]算法训练模型，求解质量均优于其他方法。PENG 等[16] 设计了动态编码器-解码器注意力模型，可以自主探索节点特征。BRESSON 等[17] 提出使用带有 MHA 模块的部分解构建查询，添加虚拟城市，通过自注意力查询所有城市并解码得到最优解，能有效解决 TSP 问题。收割机作业调度问题与 TSP[18]、车辆路径问题 (vehicle routing problem，VRP)[19] 具有相似性，作业车辆都需要确定最短行驶路线。BOCHTIS 等[20-21] 将求解 VRP 的方法与思想应用于农机田间作业路径规划，该方法可显著缩短农机在田间的转移距离，提高作业效率，降低作业成本。ALI 等[22] 将 VRP 与最小成本网络流问题结合，解决联合收割机作业路径问题，极大减少了收割机的非作业成本。

目前传统启发式算法通常依赖设计者提供的专家知识和领域知识，并不具备自主学习和决策能力[23]。而深度强化学习方法能够从局部信息入手，通过不断试错找到更优策略。深度强化学习结合深度神经网络高效利用原始数据，自动学习环境中的复杂情况，避免了传统方法中人工设计特征，降低了对先验知识的依赖，同时深度神经网络有更强的函数逼近能力[24]，这使得该方法相较于传统启发式算法更适于复杂环境，具有更强的泛化能力。

为此，本文拟借助深度强化学习的自学习能力，提出收割机省内协同调度优化策略，采用“编码器-解码器”架构，通过自注意力机制不断学习农田数据特点，利用近端策略优化算法不断训练网络模型，以期找到更优的收割机调度方案。

1 问题与模型

1.1 问题描述

本文中待作业农田所属区域为同一县域或相邻县域，收割机协同调度优化问题描述如下：已知该作业区域有 m 块待作业农田，某农机调度中心有 k 台收割机，综合考虑收割机的作业性能、待作业农田的作业时长、位置等信息，为收割机提供最佳的作业服务路径，保证在完成所有作业任务的前提下，实现收割机地块间转移成本最低。收割机作业场景复杂多变，为便于研究，本文做如下假设：

①每台收割机作业能力相同，收割机作业转移过程中匀速行驶，作业过程中暂不考虑发生故障的情况；

②每台收割机从农机调度中心出发，完成所有作业任务后，均返回农机调度中心；

③每块农田只允许一台收割机作业；

④每台收割机的作业总时长不能超过最大有效作业时长，即收割机作业时长，不包括田块间转移时间。

1.2 收割机协同调度优化数学模型

为构建多机协同调度模型，本文将对主要变量和参数进行数学描述和定义，具体如下。

机群集合$HC=\{hc_1，hc_2，...hc_r\}$，$r\in[1,k]$；农田作业点集合$X=\{x_0,x_1，...x_i\}$，$x_i=\{n_i,o_i\}$，$i\in[0,m]$，其中$n_i=(u_i,v_i)$，u_i、v_i分别表示第 i 块农田的纬度坐标和经度坐标，o_i表示收割机完成第 i 块农田作业任务所需要的时长，其中，完成农田作业任务所需时长只与农田面积以及收割机作业能力有关，n_0表示农机调度中心坐标，o_0农机调度中心所需作业时长为 0；收割机已作业时长集合$TL=\{T_1,T_2,...T_r\},r\in[1,k]$。

以最小调度成本为目标函数，构建收割机协同调度模型，目标函数如下：

$$cost_Z=P\cdot\sum_{i=0}^{m}\sum_{j=0}^{m}\sum_{r=1}^{k}d_{ij}D_{ijr} \tag{1}$$

式中$cost_Z$表示收割机调度成本，元；P 表示收割机单位转移距离成本，元；d_{ij}表示农田作业点 i 到农田作业点 j 的距离，km；收割机 r 从农田作业点 i 转移到农田作业点 j 并完成作业任务时D_{ijr}=1，否则D_{ijr}=0。

约束条件:

$$\sum_{j=1}^{m}D_{0jr}=\sum_{i=1}^{m}D_{i0r}，\ r\in[1,k] \tag{2}$$

$$\sum_{i=1}^{m}\sum_{r=1}^{k}D_{ijr}=1，\ j\in[1,m] \tag{3}$$

$$\forall T_r\leqslant T_{\max},\ r\in[1,k] \tag{4}$$

式（2）表示收割机从农机调度中心出发完成作业任务后均会返回农机调度中心；式（3）表示每块农田只允许一台收割机进行作业服务；式（4）中$T_{\max}$表示每台收割机的最大有效作业时长，h。

2 基于深度强化学习的收割机协同调度优化算法

首先搭建深度强化学习环境，将收割机协同调度过程描述为马尔可夫决策过程 (markov decision process，MDP)[25]；设计基于自注意力机制的策略网络和由 3 个全连接层组成的价值网络模型；然后根据混合动作选择策略选择收割机下一步执行的动作，与环境交互，记录轨迹数据并存入经验池；通过近端优化策略算法训练神经网络模型，得到多约束条件下的最优收割机调度策略；最后试验验证效果并进行对比分析。求解流程如图 1 所示。

2.1 搭建深度强化学习环境

每台收割机从调度中心出发，根据调度中心规划的作业路线完成收割任务并记录地块间的转移距离。完成作业后，收割机基于当前状态选择新的待作业农田。重复上述过程，直到完成所有农田作业。调度过程中收割机的转移只依赖于上一块已作业农田和当前剩余有效作业时长，搭建基于马尔可夫决策的深度强化学习环境，具体如下：

1）定义状态空间$s_t=\{x_i^t,u_t\}$，$i\in[0,m]$，其中x_i^t表示 t 时刻收割机所在第 i 个农田作业点的位置以及完成当前农田作业点作业任务需要的时长；u_t表示 t 时刻收割机剩余有效作业时长。

2）动作空间采用离散形式，动作数量与农田作业点

数量相同。收割机每个 t 时刻在未作业的农田作业点中选择下一步要作业的对象，动作 $a_t=\{n_i'\}$ 表示收割机在 t 时刻转移到 i 农田作业点并完成作业。

3）奖励函数 r_t 是影响收割机动作好坏的关键因素，本文奖励函数定义为收割机调度成本的负数，即：

$$r_t=-\sum_{t=1}^{T}\mathrm{dist}(a_t,a_{t+1})\cdot P \tag{5}$$

式中 T 表示训练时间总步长；表示 t 时刻收割机选择要作业的对象；$\mathrm{dist}(x,y)$ 表示 x，y 两点间的欧氏距离，km。

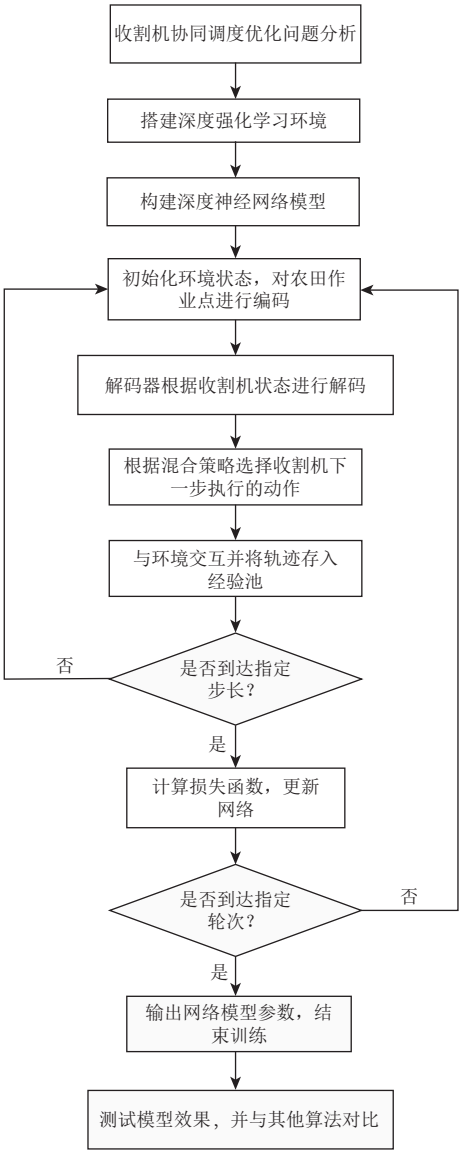


图 1　基于深度强化学习的收割机协同调度优化问题求解流程

Fig.1　Solution process for collaborative scheduling optimization problem of harvesters based on deep reinforcement learning

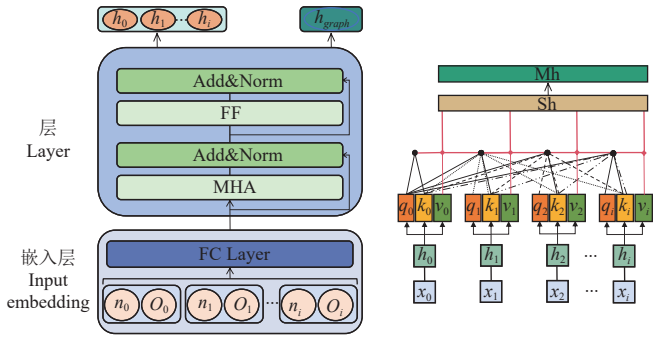
2.2　构建深度神经网络模型

构建基于编码器-解码器架构的策略网络，通过编码器将输入的农田作业点映射为特征编码，并计算全局上下文信息；解码器按照农田作业点状态和收割机状态计算农田作业点可被收割机选择作业的概率。

2.2.1　编码器设计方案

编码器堆栈由 6 个相同且相互独立的编码器堆叠串联组成，每个编码器内部由多头注意力机制 MHA 和前馈全连接网络 (feed-forward layer，FF) 构成。为了避免梯度消失和加速网络收敛，在 MHA 与 FF 中加入残差连接 (residual connection) 和批标准化 (batch normalization)。

相比于单头注意力，多头注意力机制融合多个单头注意力 (single-head attention，SHA) 的计算结果，能从不同角度提取农田作业点的特征，增强网络特征表达能力。前馈全连接网络可以进一步变换注意力输出，获得农田作业点的深层语义信息。编码器与多头注意力结构如图 2 所示。



注：FC Layer 表示线性层，Add&Norm 表示残差链接和标准化，$\boldsymbol{h_{graph}}$ 表示上下文特征编码，n_i 表示农田作业点的经纬度坐标，O_i 表示农田作业点所需作业时长，$\boldsymbol{h_i}$ 表示嵌入向量，$\boldsymbol{q_i}$ 表示查询向量，$\boldsymbol{k_i}$ 表示键向量，$\boldsymbol{v_i}$ 表示值向量，Sh 表示单头注意力计算结果，Mh 表示最终融合的多头注意力结果，$i=[0,1,2,...,m]$，m 为农田作业点数量。

Note: FC Layer represents a linear layer, Add&Norm represents residual connections and normalization, $\boldsymbol{h_{graph}}$ represents context feature encoding, n_i represents the latitude and longitude coordinates of the farmland operation point, and O_i represents the required operation time for the farmland operation point, $\boldsymbol{h_i}$ represents the embedding vector, $\boldsymbol{q_i}$ represents the query vector, $\boldsymbol{k_i}$ represents the key vector, $\boldsymbol{v_i}$ represents the value vector, Sh represents the result of single-head attention calculation, Mh represents the final fused multi-head attention result, $i=[0,1,2,...,m]$, m represents the number of farmland operation points。

图 2　编码器与多头注意力机制结构图

Fig.2　Encoder and multi-head attention mechanism structure diagram

为了更好捕捉农田作业点之间的关系，本文将农田作业点集合 X 输入到编码器的嵌入层，嵌入层将每个农田作业点 x_i 线性投影为 128 维嵌入向量 $\boldsymbol{h_i}$，$i\in[0,m]$，即：

$$\boldsymbol{h_i}=W^X x_i+b^X \tag{6}$$

式中 $\boldsymbol{W^X}$ 和 $\boldsymbol{b^X}$ 为可训练参数。嵌入向量 $\boldsymbol{h_i}$ 会在第一层编码器的多头注意力机制中进行计算。首先嵌入向量 $\boldsymbol{h_i}$ 通过线性映射，生成编码器使用的一个查询向量 $\boldsymbol{Q}_1$、一个键向量 $\boldsymbol{K}_1$ 与一个值向量 $\boldsymbol{V}_1$。接着对 $\boldsymbol{Q}_1$ 和 $\boldsymbol{K}_1$ 进行点积运算，得到能够表示农田作业点之间依赖程度的相关性得分 score。为避免结果过大，将 score 按 $1/\sqrt{d_{K_1}}$ 进行缩放，d_{K_1} 为键向量的维度。为了更凸显农田作业点之间的关系，使用 softmax 函数将 score 转换为概率分布矩阵。使用概率分布矩阵与值向量 $\boldsymbol{V}_1$ 进行点积运算，得到每个 SHA 的注意力向量 $\boldsymbol{hd}_z$，即：

$$\boldsymbol{hd}_z=\mathrm{softmax}\left(\frac{\boldsymbol{Q}_1\boldsymbol{K}_1'}{\sqrt{d_{K_1}}}\right)\boldsymbol{V}_1 \tag{7}$$

其中 MHA 头数 H=8，$z\in[1,H]$；$\boldsymbol{K}_1'$ 表示 $\boldsymbol{K}_1$ 的转置矩阵。最后，将每个单头注意力向量拼接，得到最终的多头注

意力矩阵 $\boldsymbol{M}$，即：

$$\boldsymbol{M}=\text{concat}(\boldsymbol{hd}_1,...,\boldsymbol{hd}_z)\boldsymbol{W}^O \tag{8}$$

式中$\boldsymbol{W}^O$为可学习的权重矩阵。多头注意力矩阵 $\boldsymbol{M}$ 经过前馈全连接网络 FF 层后，被处理为更能够进一步表示农田作业点之间关系的特征编码$\boldsymbol{h}_i^{(1)}$，这些特征编码依次经过当前编码器后会被更新为新的特征编码$\boldsymbol{h}_i^{(l)}$，$l\in[1,N]$。对最后一层编码器输出的特征编码$\boldsymbol{h}_i$取平均值，作为全局的上下文特征编码$\boldsymbol{h}_{graph}$，即：

$$\boldsymbol{h}_{graph}=\frac{1}{n}\sum_{i=0}^{m}\boldsymbol{h}_i \tag{9}$$

2.2.2 解码器设计方案

根据收割机调度作业和编码器的编码过程，设计双注意力机制解码器，即多头注意力机制和单头注意力机制。

解码器每个时刻 t 的输入分为 3 部分：嵌入向量$\boldsymbol{h}_i$、编码器的输出和当前环境的观测值$O_{(t)}$。其中，编码器输出包含特征编码h_i与上下文特征编码$\boldsymbol{h}_{graph}$。当前环境观测值$O_{(t)}$包括上一个已完成作业的农田作业点x_i^{t-1}和收割机剩余有效工作时长u_t。

首先解码器的嵌入层提取x_i^{t-1}对应的农田特征向量$\boldsymbol{h}_i$，并与收割机当前剩余的有效工作时长u_t进行拼接，作为当前状态上下文信息$\boldsymbol{Sc}_{(t)}$，即：

$$\boldsymbol{Sc}_{(t)}=\boldsymbol{W}^x\cdot\text{concat}(\boldsymbol{h}_i,u_t)+b^x \tag{10}$$

式中 b^x 为可训练参数，将$\boldsymbol{Sc}_{(t)}$与上下文特征编码$\boldsymbol{h}_{graph}$进行合并，作为充分表达当前 t 时刻解码状态的上下文相关向量$\widehat{\boldsymbol{q}}_{(t)}$，以指导策略网络决策，即：

$$\widehat{\boldsymbol{q}}_{(t)}=\boldsymbol{h}_{graph}+\boldsymbol{Sc}_{(t)} \tag{11}$$

然后通过映射农田作业点特征向量$\boldsymbol{h}_i$，生成解码器的键向量$\widehat{\boldsymbol{K}}$与值向量$\widehat{\boldsymbol{V}}$，并对$\widehat{\boldsymbol{q}}_{(t)}$、$\widehat{\boldsymbol{K}}$与$\widehat{\boldsymbol{V}}$进行降维，分别作为不同 SHA 中的查询向量$\widehat{\boldsymbol{q}}_{(t)}^z$、键向量$\widehat{\boldsymbol{K}}^z$,与值向量$\widehat{\boldsymbol{V}}^z$，$z\in[1,H]$。通过计算当前 t 时刻$\widehat{\boldsymbol{q}}_{(t)}^z$和$\boldsymbol{K}^z$的点积，得到不同 SHA 对应的相关性得分$s_{i,t}^z$，$i\in[0,m]$。在计算过程中，设置以下规则屏蔽不可作业的农田作业点：1）不允许重新作业已经作业过的农田作业点。2）不允许作业时长超过收割机剩余有效工作时长的农田作业点。即：

$$\boldsymbol{s}_{i,t}^z=\begin{cases}\dfrac{\widehat{\boldsymbol{q}}_{(t)}^z\widehat{\boldsymbol{K}}^{z'}}{\sqrt{d_{\widehat{K}^z}}},\text{非屏蔽农田作业点}\\ -\infty，\text{屏蔽农田作业点}\end{cases} \tag{12}$$

式中$\widehat{\boldsymbol{K}}^{z'}$表示$\widehat{\boldsymbol{K}}^z$的转置矩阵，$\sqrt{d_{\widehat{K}^z}}$表示不同注意力头键向量的维度。接下来计算每个单头注意力向量$\boldsymbol{o}_t^z$，即：

$$\boldsymbol{o}_t^z=\text{softmax}\left(\boldsymbol{s}_{i,t}^z\right)\widehat{\boldsymbol{V}}^z \tag{13}$$

接着将每个单头注意力向量$\boldsymbol{o}_t^z$拼接起来，经过线性层映射，得到最终的多头注意力向量$\boldsymbol{A}_t$，即

$$\boldsymbol{A}_t=\text{concat}(\boldsymbol{o}_t^1,...,\boldsymbol{o}_t^z)\boldsymbol{W}^y \tag{14}$$

式中$\boldsymbol{W}^y$是一个可学习的权重矩阵。

最后，将多头注意力向量$\boldsymbol{A}_t$作为单头注意力的查询向量，通过解码器的单头注意力计算最终的农田作业点相关性得分$s_{i,t}$，并使用 tanh 函数将计算结果裁剪在$[-C,C]$范围内，即：

$$s_{i,t}=\begin{cases}C\cdot\tanh\left(\dfrac{\boldsymbol{A}_t\widehat{\boldsymbol{K}}'}{\sqrt{d_{\widehat{K}}}}\right),\text{非屏蔽农田作业点}\\ -\infty，\text{屏蔽农田作业点}\end{cases} \tag{15}$$

式中 tanh 为双曲正切函数，裁剪系数 C=10，$\widehat{\boldsymbol{K}}'$表示$\widehat{\boldsymbol{K}}$的转置矩阵。使用 softmax 函数得到最终的农田作业点的概率分布$p_{i,t}$，即：

$$p_{i,t}=\text{softmax}(s_{i,t}) \tag{16}$$

根据农田作业点的概率分布$p_{i,t}$，由混合动作选择策略选择收割机下一个作业点。

2.3 动作选择策略

在强化学习中，常见的动作选择策略包括贪婪策略和随机采样策略。贪婪策略是指每一步都选择概率最大的动作，以获取局部最优解并快速逼近全局最优解。随机采样策略是指根据概率分布对要选择的节点进行随机抽样，可以更充分地探索动作空间。

本文采用上述方式的混合动作采样策略，即在训练阶段使用带动态高斯噪声[21]的随机采样，根据训练步数调整动态高斯噪声的噪声标准差σ并添加到概率分布$p_{i,t}$中，实现噪声标准差σ的动态衰减。在测试阶段使用贪婪策略，选择概率最大的动作，即：

$$a_t=\max(p_{i,t}+\sigma) \tag{17}$$

式中初始$\sigma=0.1$，终止时$\sigma=0.001$。这种混合采样策略结合了随机采样策略的探索与贪婪采样策略的利用，使策略网络鲁棒性更强，获得更佳的训练效果。

2.4 网络模型训练

本文使用强化学习近端策略优化算法 (proximal policy optimization，PPO)[26] 训练 DRL-ICOSA 算法的策略网络和价值网络模型，价值网络与策略网络共享相同的解码器输出。

实现 PPO 算法关键在于构建一个能够有效降低方差的优势函数[27]。该优势函数用于评价特定状态下采取某个动作的优劣。在强化学习领域中，广义优势估计 (generalized advantage estimation，GAE)[28] 是构建优势函数最为高效的方法之一。在计算 GAE 的过程中，首先利用价值网络预测收割机在当前 t 时刻完成所有作业任务的总调度成本，并将其作为基线。然后基于训练时间总步长 T 的策略，利用收集到的收割机作业轨迹进行计算和更新。GAE 函数G_t定义如下：

$$G_t=\delta_t+(\gamma\lambda)\delta_{t+1}+...+(\gamma\lambda)^{T-t+1}\delta_{T-1} \tag{18}$$

式中δ_t为时差误差，$\delta_t=r_t+\gamma V_\phi(s_{t+1})-V_\phi(s_t)$；$V_\phi(s_t)$表示价值网络预测的总调度成本，元；$\gamma$为折扣因子，$\lambda$为 GAE 的超参数。

之后通过计算均方误差 (mean squared error，MSE) 损失，得到价值损失函数$J_{VF}(\theta)$，用以训练价值网络，计算式如下：

$$J_{VF}(\theta)=\text{MSE}(G_t) \tag{19}$$

将经验池中的轨迹数据再次输入到策略网络进行重新计算，得到新旧策略概率，通过裁剪新旧策略比率控制策略的更新范围，从而高效更新策略网络，其策略损

失函数$J_{Clip}(\theta)$定义如下：

$$J_{Clip}(\theta)=\widehat{\mathbb{E}}[\min(r_t(\theta)G_t,\mathrm{clip}(r_t(\theta),1-\varepsilon,1+\varepsilon))G_t] \tag{20}$$

式中$r_t(\theta)$表示新策略与旧策略之间的比率，$r_t(\theta)=\dfrac{p_\theta(a_t|s_t)}{p_{\theta_{old}}(a_t|s_t)}$；$p_\theta(a_t|s_t)$、$p_{\theta_{old}}(a_t|s_t)$分别表示在新旧策略下，收割机在当前农田作业点时选择下一个要作业的农田作业点的概率；ε为超参数；clip函数的作用是裁剪新旧策略的概率比率。

PPO 算法的终级目标是通过组合优化策略损失、价值函数误差和策略熵损失[29]进行有效的探索和更新，获得更好的策略，策略熵损失函数$J_E(\theta)$为

$$J_E(\theta)=\mathrm{Entropy}(p_\theta(a_t|s_t)) \tag{21}$$

最终的总损失函数$J_{Loss}(\theta)$为

$$J_{Loss}(\theta)=J_{Clip}(\theta)-c_1J_E(\theta)+c_2J_{VF}(\theta) \tag{22}$$

式中c_1、c_2为权重；$J_{Clip}(\theta)$为策略损失函数；$J_{VF}(\theta)$为价值误差函数。

3　仿真与结果分析

为验证算法的有效性，本文对多种算法进行仿真对比。

3.1　训练数据

基于河北省小麦种植区域 (北纬 36°～41°，东经 113°～117°）2022 年 8 月遥感影像数据，随机选取 10000 组农田作业数据组成训练集。其中每组数据涵盖 1 个农机调度中心和 50 块农田信息，包括调度中心经纬度坐标、农田经纬度坐标及农田面积。

训练的目的是优化收割机协同调度策略以达到成本最低，由 2.1 节式（5）可知，奖励值为调度成本的负数。训练过程中奖励值变化情况如图 3 所示。

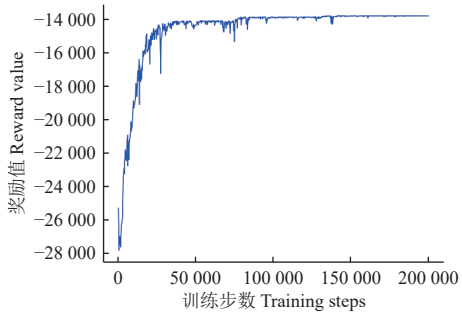


图 3　奖励值变化情况

Fig.3　Changes in reward values

奖励值是影响收割机动作好坏的关键因素。在训练初期，由于模型尚未足够深入理解环境且受动态噪声的影响，初始调度策略的奖励值相对较低，即调度成本较高。当训练累积到大约 150 000 步时，奖励值趋于收敛，模型逐渐适应数据并改进策略，调度成本逐步降低。当训练到达预定的最大步数 200 000 时，模型已达到当前环境下的最佳状态，能够快速规划出成本最低的调度方案。

3.2　试验数据

为验证本文算法的有效性和适用性，从 2023 年 6 月份河北省遥感影像数据中获取小麦种植区的真实农田作业数据作为测试集。从邯郸市临漳县（北纬 36.1°～36.4°，东经 114.5°～114.8°）的遥感影像数据中选取一组农田作业数据，临漳遥感影像如图 4 所示。

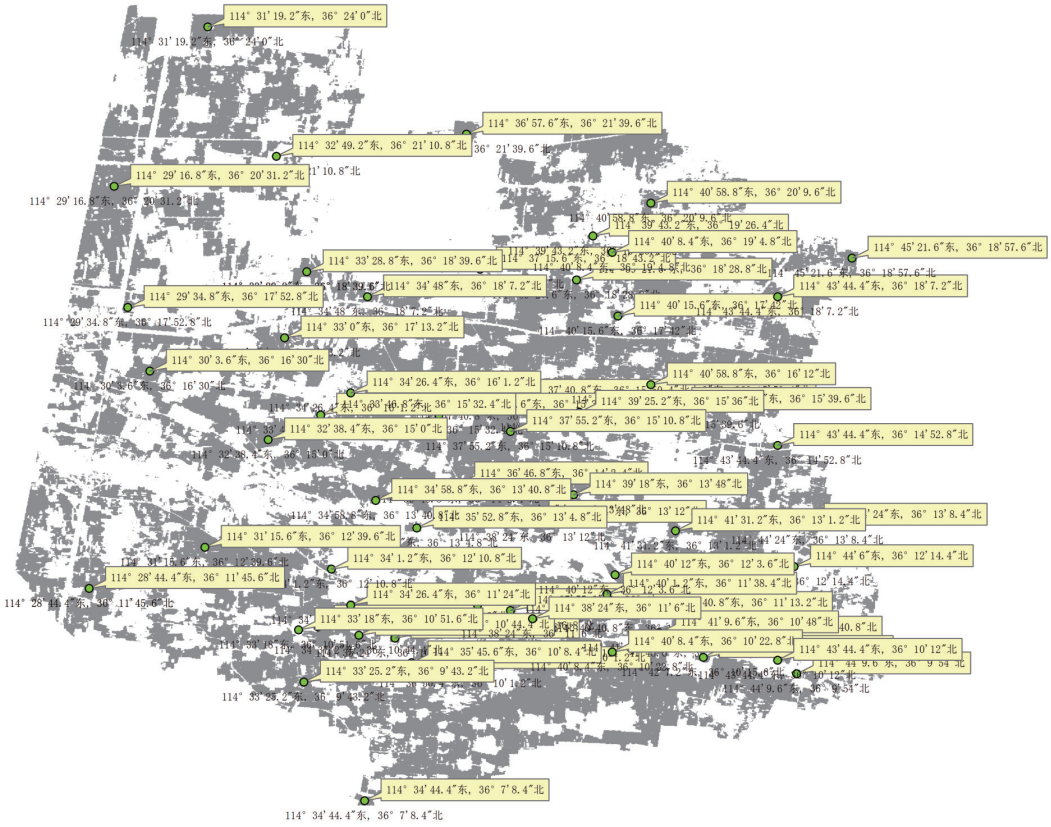


图 4　邯郸市临漳县农田遥感影像

Fig.4　Remote sensing images of farmland Linzhang County, Handan City

农机型号为沃得半喂入式 4 LB-150AA 型谷物联合收割机，油耗约为 1.7 L/km，2024 年 1—4 月平均柴油价格约为 8.2 元/L，故收割机每公里转移成本为 14 元。农忙季节，作业任务繁重且时间集中，收割机常常要连续工作。因此试验中设定收割机有效作业时长为 24 h。

临漳县农田作业点具体数据如表 1 所示。

表 1 农田作业点数据

Table 1 Farmland operation point data

农田作业点编号 Farmland operation point No.	纬度 Latitude/(°)	经度 Longitude/(°)	种植面积 Planting area/km^2
0	36.257	114.625	0
1	36.178	114.590	0.804
2	36.169	114.596	0.201
3	36.220	114.640	0.804
4	36.188	114.632	1.608
5	36.392	114.522	1.608
6	36.187	114.678	0.603
7	36.190	114.574	1.206
8	36.165	114.736	0.402
9	36.230	114.655	1.608
10	36.248	114.729	1.206
11	36.264	114.628	0.402
12	36.302	114.580	0.603
13	36.361	114.616	1.809
14	36.259	114.606	1.206
15	36.353	114.547	0.201
16	36.259	114.563	0.804
17	36.270	114.683	0.804
18	36.324	114.662	0.804
19	36.344	114.715	0.402
20	36.261	114.692	1.608
21	36.179	114.577	1.407
22	36.171	114.702	0.804
23	36.181	114.555	0.402
24	36.311	114.558	1.608
25	36.194	114.667	0.603
26	36.316	114.756	1.407
27	36.308	114.656	1.206
28	36.250	114.544	1.809
29	36.162	114.557	1.005
30	36.167	114.538	1.608
31	36.190	114.620	1.809
32	36.219	114.740	1.206
33	36.204	114.735	0.603
34	36.119	114.579	1.005
35	36.203	114.567	0.804
36	36.336	114.683	0.804
37	36.185	114.640	0.402
38	36.260	114.657	1.608
39	36.180	114.530	1.809
40	36.127	114.623	1.206
41	36.201	114.670	1.608
42	36.217	114.692	1.608
43	36.253	114.632	1.608
44	36.228	114.583	1.206
45	36.267	114.574	0.201
46	36.170	114.729	0.201
47	36.373	114.531	1.809
48	36.264	114.672	0.402
49	36.312	114.621	0.201
50	36.234	114.613	1.005

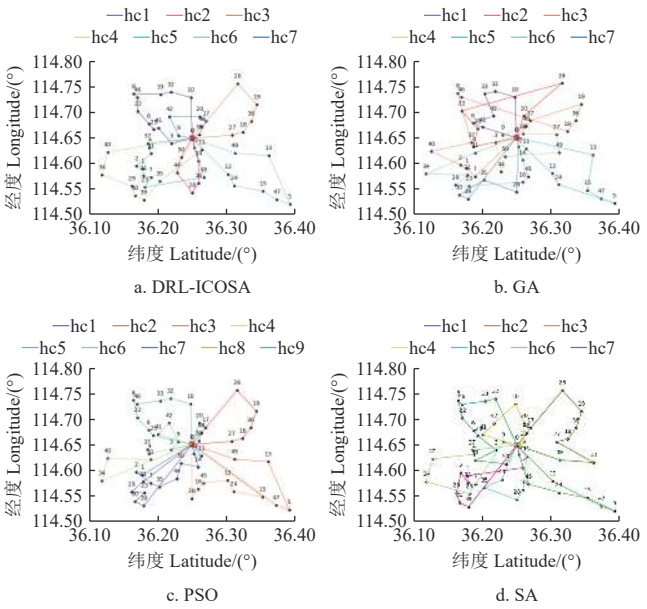
注：编号 0 为农机调度中心。

Note: No. 0 is the data from the agricultural machinery dispatch center.

3.3 试验结果与分析

在农机调度中心位于区域中心、收割机数量充足且每台收割机工作时长不超过 24 h 的情况下，以最小化调度成本为目标，分别选用遗传算法 GA、粒子群算法 PSO、模拟退火算法 SA 与本文算法 DRL-ICOSA 计算最优调度方案。

4 种算法的调度方案如图 5 所示，调度成本对比如表 2 所示。



注：圆点表示农田，方块表示调度中心，数字表示农田作业点的编号，其中调度中心编号为 0，每一条封闭折线代表一辆收割机在农田作业点间的作业路径，hc1 表示 1 号收割机，hc2 表示 2 号收割机，其余以此类推。

Note: The dot represents the farmland, the square represents the dispatching center, and the number represents the number of the farmland operation point. The dispatching center number is 0. Each closed broken line represents the operation path of a harvester between the farmland operation points, hc1 represents harvester 1, hc2 represents harvester 2, and so on.

图 5 不同算法的调度方案

Fig.5 Scheduling schemes for different algorithms

表 2 不同算法的调度结果对比

Table 2 Comparison of scheduling results of different algorithms

算法 Algorithm	收割机调度路线 Harvester scheduling route	总行驶距离 Total driving distance/km	调度成本 Scheduling costs/元
DRL-ICOSA	0-10-32-33-8-46-22-6-25-41-3-0 0-9-42-20-17-38-0 0-37-4-31-2-1-21-7-23- 45-0 0-49-13-5-47-15-24-12-0 0-40-34-29-30-39-35-11-0 0-48-26-19-36-18-27-0 0-43-14-16-28-44-50-0	238.92	3 344.88
GA	0-10-32-33-42-6-41-0 0-43-28-35-30-39-0 0-11-12-24-5-47-15-13-0 0-31-34-21-29-23-16-45-14-0 0-9-48-38-27-49-50-44-3-0 0-17-19-36-18-46-8-37-40-2-1-7-0 0-20-26-22-25-4-0	326.37	4 569.18
PSO	0-21-29-23-30-39-0 0-20-17-48-38-43-11-0 0-14-50-44-35-7-2-1-0 0-49-13-5-47-0 0-41-42-9-3-0 0-28-16-45-12-24-15-0 0-10-32-33-46-8-22-6-25-0 0-27-18-36-19-26-0 0-34-40-31-4-37-0	294.69	4 125.66
SA	0-32-33-46-8-22-6-25-3-31-50-0 0-38-20-10-42-41-0 0-48-17-26-19-36-18-27-13-49-0 0-12-47-5-15-24-45-0 0-11-16-28-35-44-0 0-43-14-1-21-2-29-30-39-0 0-9-7-23-34-40-4-37-0	270.93	3 793.02

由表 2 可知，DRL-ICOSA 算法计算得到的调度成本相较于 GA、PSO 和 SA 算法，分别减少了约 36.6%、23.3% 和 13.3%。

3.4　作业时长与地理布局对调度成本的影响分析

综合考虑作业时长和农机调度中心地理布局等因素，开展多作业场景下的试验与对比，进一步验证本文算法的有效性。

试验数据来源于 2023 年 6 月河北省遥感影像数据。针对不同作业场景，选取 10 组农田作业数据进行算法试验，DRL-ICOSA 算法与 GA、PSO 和 SA 算法调度成本分析如表 3 所示。

由表 3 可知，当作业时长为 40 h，调度中心位于区域中心或边缘时，每组试验 DRL-ICOSA 算法均能保持调度成本最低。当作业时长为 24 h，调度中心位于区域中心或边缘时，得到相同的结论。在 4 种作业场景下，分别运用 4 种算法对 10 组试验数据计算得到的平均调度成本对比分析如表 4、表 5 所示。

表 3　不同作业场景下调度成本分析

Table 3　Analysis of scheduling costs in different job scenarios

作业时长 Operation duration/h	调度中心位置 Movement control center locations	作业场景 Operating environment	调度成本 Scheduling costs/元			
			DRL-ICOSA	GA	PSO	SA
40	区域中心	场景 1	16 721.04	18 554.76	18 539.22	17 637.90
			14 312.34	17 606.82	16 658.88	15 804.18
			14 405.58	18 694.62	17 342.64	15 975.12
			14 623.14	18 275.04	17 622.36	16 177.14
			15 167.04	18 041.94	16 643.34	16 099.44
			14 063.70	18 803.40	17 793.30	15 726.48
			13 690.74	18 321.66	17 358.18	16 348.08
			14 156.94	18 508.14	17 296.02	17 078.46
			13 348.86	17 684.52	16 845.36	16 519.02
			12 944.82	17 125.08	16 099.44	16 006.20
	区域边缘	场景 2	23 123.52	31 328.64	29 945.58	28 174.02
			22 004.64	28 189.56	26 480.16	24 646.44
			21 181.02	30 023.28	25 112.64	23 978.22
			21 662.76	29 463.84	25 858.56	23 947.14
			20 295.24	29 541.54	25 423.44	23 341.08
			22 268.82	30 194.22	26 402.46	25 034.94
			22 362.06	28 826.70	26 620.02	24 040.38
			21 243.18	27 474.72	25 050.48	23 387.70
			19 549.32	27 334.86	24 832.92	24 087.00
			22 470.84	28 686.84	27 365.94	25 843.02
24	区域中心	场景 3	18 523.68	24 491.04	21 616.14	20 854.68
			16 565.64	23 061.36	20 419.56	20 279.70
			18 989.88	23 263.38	21 056.70	20 497.26
			17 855.46	23 512.02	21 429.66	20 839.14
			17 218.32	22 999.20	20 559.42	19 362.84
			18 927.72	23 884.98	22 315.44	20 792.52
			19 751.34	24 428.88	22 330.98	20 994.54
			17 575.74	23 247.84	21 585.06	20 621.58
			20 264.16	24 615.36	23 107.98	21 926.94
			20 637.12	25 547.76	23 403.24	22 999.20
	区域边缘	场景 4	33 348.84	39 207.42	37 311.54	35 866.32
			31 017.84	38 430.42	36 099.42	35 337.96
			30 411.78	38 477.04	36 223.74	35 042.70
			29 914.50	35 167.02	33 752.88	33 224.52
			31 825.92	37 435.86	35 695.38	34 840.68
			31 048.92	37 513.56	35 757.54	34 156.92
			28 360.50	34 529.88	31 639.44	32 478.60
			28 236.18	32 960.34	30 955.68	30 769.20
			26 635.56	31 157.70	30 598.26	29 184.12
			29 603.70	35 058.24	34 017.06	34 172.46

表 4　不同作业时长下不同算法的平均调度结果对比分析

Table 4　Comparative analysis of average scheduling results of different algorithms under different homework durations

作业时长 Operation duration/h	作业场景 Operating environment	平均调度成本 Average scheduling cost/元				平均调度成本降低率 Average scheduling cost reduction rate/%		
		DRL-ICOSA	GA	PSO	SA	GA	PSO	SA
40	场景 1	14 343.420	18 161.598	17 219.874	16 337.202	26.6	20.1	13.9
	场景 2	21 616.140	29 106.420	26 309.220	24 647.994	34.7	21.7	14.0
24	场景 3	18 630.906	23 905.182	21 782.418	20 916.840	28.3	16.9	12.3
	场景 4	30 040.374	35 993.748	34 205.094	33 507.348	18.5	13.9	11.5

由表 4、表 5 可知：1）调度中心位于区域中心，当收割机有效作业时长为 40 h，平均调度成本与 GA、PSO 和 SA 算法相比，本文算法的平均调度成本降幅分别为 26.6%、20.1% 和 13.9%。当作业时长为 24 h 时，平均调度成本降幅分别为 28.3%、16.9% 和 12.3%。

2）调度中心位于区域边缘，当作业时长为 40 h，DRL-ICOSA 算法相较于其他 3 种算法，平均调度成本降幅达到了 34.7%、21.7% 和 14%。当作业时长为

24 h 时，DRL-ICOSA 算法与 GA、PSO 和 SA 算法相比，依旧保持最低的调度成本，平均调度成本降幅为 18.5%、13.9% 和 11.5%。当调度中心位于区域中心或边缘，收割机有效作业时长为 40 或 24 h 时，与 GA、PSO 和 SA 算法相比，本文算法得到的调度成本均为最低。

表 5 2 种调度中心地理布局下不同算法的平均调度结果对比分析

Table 5 Comparative analysis of average scheduling results of different algorithms under 2 scheduling center geographic layouts

调度中心位置 Movement control center locations	作业场景 Operating environment	平均调度成本 Average scheduling cost/元				平均调度成本降低率 Average scheduling cost reduction rate/%		
		DRL-ICOSA	GA	PSO	SA	GA	PSO	SA
区域中心	场景 1	12 707.408	16 478.672	15 176.504	14 527.352	29.6	19.4	14.3
	场景 3	17 051.832	21 492.856	19 745.040	19 490.016	26.0	15.7	14.2
区域边缘	场景 2	19 479.712	25 430.272	23 199.456	21 572.712	30.5	19.1	10.7
	场景 4	27 617.296	33 216.489	31 549.560	31 165.736	20.2	14.2	12.8

4 结 论

为解决收割机省内协同调度问题，本文提出一种基于深度强化学习的收割机协同调度优化算法（DRL-ICOSA），并与遗传算法（GA）、粒子群算法（PSO）和模拟退火算法（SA）进行比较，得出以下结论：

1）通过不同作业时长的试验验证，DRL-ICOSA 算法在降低调度成本方面明显优于 GA、PSO 和 SA 算法。当作业时长为 40 h 时，平均调度成本降幅不低于 13.9%，作业时长为 24 h 时，平均调度成本降幅不低于 11.5%。试验结果证明，DRL-ICOSA 算法不受 2 种作业时长的影响，能够有效规划出低成本的调度方案。

2）通过调整调度中心地理布局进行试验，结果证明 DRL-ICOSA 算法不受 2 种农机调度中心地理布局的影响。当调度中心位于区域中心时，相较于其他算法，平均调度成本降幅不低于 12.3%。当调度中心转移至区域边缘位置时，DRL-ICOSA 算法的平均调度成本较其他算法降幅不低于 11.5%。

未来的研究将致力于进一步优化收割机的调度成本，特别是考虑到收割机启动成本的影响。这将进一步提升调度方案的经济效益和实际应用价值。

[参 考 文 献]

[1] ZHANG Q K, CAO G Q, ZHANG J J, et al. Simulated annealing genetic algorithm-based harvester operation scheduling model.[J]. INMATEH-Agricultural Engineering, 2021, 63(1): 249-260.

[2] 张帆，罗锡文，张智刚，等. 基于改进多父辈遗传算法的农机调度优化方法[J]. 农业工程学报，2021，37(9)：192-198.
ZHANG Fan, LUO XiWen, ZHANG Zhigang et al. Agricultural machinery scheduling optimization method based on improved multi-parents genetic algorithm[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(9): 192-198. (in Chinese with English abstract).

[3] 黄凰，陈燕燕，朱明，等. 基于模糊隶属度的多站点多机协同即时响应调度系统[J]. 农业工程学报，2021，37(21)：71-79.
HUANG Huang, CHEN Yanyan, ZHU Ming, et al. Multi-site and multi-machine cooperative instant response scheduling system based on fuzzy membership[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2021, 37(21): 71-79. (in Chinese with English abstract).

[4] 张璠，滕桂法，苑迎春，等. 农机跨区作业紧急调配算法适宜性选择[J]. 农业工程学报，2018，34(5)：47-53.
ZHANG Fan, TENG Guifa, YUAN Yingchun, et al. Suitability selection of emergency scheduling and allocating algorithm of agricultural machinery[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2018, 34(5): 47-53. (in Chinese with English abstract).

[5] ZHANG H Z, ZHANG Q W, MA L, et al. A hybrid ant colony optimization algorithm for a multi-objective vehicle routing problem with flexible time windows[J]. Information Sciences, 2019, 490: 166-190.

[6] HUANG H, CUAN X W, CHEN Z, et al. A multiregional agricultural machinery scheduling method based on hybrid particle swarm optimization algorithm[J]. Agriculture, 2023, 13(5): 1042-1060.

[7] 杨昊天，王良民，刘路，等. 基于区块链的农机跨区域调度模型构建与应用[J]. 农业工程学报，2022，38(11)：31-40.
YANG Haotian, WANG Liangmin, LIU Lu, et al. Model construction and application of agricultural machinery cross-region scheduling based on blockchain[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2022, 38(11): 31-40. (in Chinese with English abstract).

[8] 曹光乔，马斌，陈聪，等. 基于遗传变邻域搜索算法的农机跨区调度优化研究[J]. 农业机械学报，2023，54(10)：114-123.
CAO Guangqiao, MA Bin, CHEN Cong, et al. Agricultural machinery cross-region scheduling optimization based on genetic algorithm variable neighborhood search[J]. Transactions of the Chinese Society for Agricultural Machinery, 2023, 54(10): 114-123. (in Chinese with English abstract).

[9] 吕帅，龚晓宇，张正昊，等. 结合进化算法的深度强化学习方法研究综述[J]. 计算机学报，2022，45(7)：1478-1499.

LV Shuai, GONG Xiaoyu, ZHANG Zhenghao, et al. Survey of deep reinforcement learning methods with evolutionary algorithms[J]. Chinese Journal of Computers, 2022, 45(7): 1478-1499. (in Chinese with English abstract).

[10] LEI K, GUO P, ZHAO W C, et al. A multi-action deep reinforcement learning framework for flexible job-shop scheduling problem[J]. Expert Systems with Applications, 2022, 205: 117796.

[11] MA Q, GE S W, HE D Y, et al. Combinatorialoptimization by graph pointer networks and hierarchical reinforcement learning[EB/OL]. (2019-11-12)[2023-12-5]https://arxiv.org/abs/1911.04936

[12] SCARSELLI F, GORI M, TSOI A H, et al. The graph neural network model[J]. IEEE Transactions on Neural Networks, 2008, 20(1): 61-80.

[13] KOOL W, VAN Hoof H, WELLING M. Attention, learn to solve routing problems![EB/OL]. (2018-3-22)[2019-02-07]https://arxiv.org/abs/1803.08475

[14] VASWANI A, SHAZZEER N, PARMAR N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems. 2017: 5998-6008.

[15] 王万良，陈浩立，李国庆，等. 基于深度强化学习的多配送中心车辆路径规划[J]. 控制与决策，2022，37(8)：2101-2109.
WANG Wanliang, CHEN Haoli, LI Guoqing, et al. Deep reinforcement learning for multi-depot vehicle routing problem[J]. Control and Decision, 2022, 37(8): 2101-2109. (in Chinese with English abstract).

[16] PENG B, WANG J H, ZHANG Z Z. A deep reinforcement learning algorithm using dynamic attention model for vehicle routing problems[C]//Artificial Intelligence Algorithms and Applications: 11th International Symposium, ISICA, Guangzhou, China, Springer Singapore, 2020.

[17] BRESSON X, LAURENT T. The transformer network for the traveling salesman problem[EB/OL]. (2021-03-04)[2023-12-7]https://arxiv.org/abs/2103.03012

[18] 李涛，邱权，赵春江，等. 矮化密植果园多臂采摘机器人任务规划[J]. 农业工程学报，2021，37(2)：1-10.
LI Tao, QIU Quan, ZHAO Chunjiang, et al. Task planning of multi-arm harvesting robots for high-density dwarf orchards[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2021, 37(2): 1-10. (in Chinese with English abstract).

[19] 庞燕，罗华丽，邢立宁，等. 车辆路径优化问题及求解方法研究综述[J]. 控制理论与应用，2019，36(10)：1573-1584.
PANG Yan, LUO Huali, XING Lining, et al. A survey of vehicle routing optimization problems and solution methods[J]. Control Theory and Applications, 2019, 36(10): 1573-1584. (in Chinese with English abstract).

[20] BOCHTIS D D, VOUGIOUKAS S G. Minimising the non-working distance travelled by machines operating in a headland field pattern[J]. Biosystems engineering, 2008, 101(1): 1-12.

[21] BOCHTIS D D, SØRENSEN C G. The vehicle routing problem in field logistics part I[J]. Biosystems Engineering, 2009, 104(4): 447-457.

[22] ALI O, VERLINDEN B, VAN OUDHEUSDEN D. Infield logistics planning for crop-harvesting operations[J]. Engineering Optimization, 2009, 41(2): 183-197.

[23] 熊俊涛，李中行，陈淑绵，等. 基于深度强化学习的虚拟机器人采摘路径避障规划[J]. 农业机械学报，2020，51(S2)：1-10.
XIONG Juntao, LI Zhongxing, CHEN Shumian, et al. Obstacle avoidance planning of virtual robot picking path based on deep reinforcement learning[J]. Transactions of the Chinese Society for Agricultural Machinery, 2020, 51(S2): 1-10. (in Chinese with English abstract).

[24] 胡洁，张亚莉，王团，等. 基于深度强化学习的农田节点数据无人机采集方法[J]. 农业工程学报，2022，38(22)：41-51.
HU Jie, ZHANG Yali, WANG Tuan, et al. UAV collection methods for the farmland nodes data based on deep reinforcement learning[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2022, 38(22): 41-51. (in Chinese with English abstract).

[25] PLAPPERT M, HOUTHOOFT R, DHARIWAL P, et al. Parameter space noise for exploration[EB/OL]. (2017-06-06)[2018-01-31]https://arxiv.org/abs/1706.01905.

[26] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[EB/OL]. (2017-07-20)[2017-08-28]https://arxiv.org/abs/1707.06347.

[27] ZHANG M, LU Y, HU Y X, et al. Dynamic scheduling method for job-shop manufacturing systems by deep reinforcement learning with proximal policy optimization[J]. Sustainability, 2022, 14(9): 5177.

[28] SCHULMAN J, MORITZ P, Levine S, et al. High-dimensional continuous control using generalized advantage estimation[EB/OL]. (2015-06-08)[2018-10-20] https://arxiv.org/abs/1506.02438.

[29] LEI K, GUO P, WANG Y, et al. Solve routing problems with a residual edge-graph attention neural network[J]. Neurocomputing, 2022, 508: 79-98.

Deep reinforcement learning-based optimization strategy for the cooperative scheduling of harvesters

LI Zikang[1] , ZHANG Fan[1,2※] , TENG Guifa[1,2,3] , LI Zheng[1] , WANG Ziyi[1] , MA Shiji[1]

(1. *School of Information Science and Technology*, *Hebei Agricultural University*, *Baoding* 071001, *China*; 2. *Key Laboratory of Agricultural Big Data*, *Hebei Province*, *Baoding* 071000, *China*; 3. *Hebei Digital Agriculture Industry Technology Research Institute*, *Shijiazhuang* 050000, *China*)

Abstract: Agricultural machinery dispatching operations, as an innovative model of socialized agricultural machinery services, have been widely implemented in county- or district-level administrative areas across the province. Due to the similar crop maturity periods within the same province, the demand for agricultural machinery is concentrated during peak operation periods, leading to a supply-demand imbalance where some machinery owners have no work while others have jobs but no machinery. This not only affects agricultural production efficiency but also increases the difficulty and complexity of agricultural production due to the lack of scientific and rational scheduling strategies. To address this challenge, many studies have adopted traditional heuristic algorithms to optimize the scheduling of harvester cooperative operations. However, issues such as low work efficiency and high operational costs remain. In response to these challenges, this study constructs a harvester co-scheduling model aimed at minimizing the transfer costs between fields. An inter-regional collaborative optimization scheduling algorithm based on deep reinforcement learning (DRL-ICOSA) was designed. This paper first analyzes the Markov decision process of harvester collaborative scheduling operations and constructs a deep reinforcement learning environment. For the attention mechanism, a policy network and a value network based on the encoder-decoder architecture were designed to enable the model to automatically learn the complexity of the environment, effectively utilize raw data, and improve performance and generalization capabilities. Dynamic Gaussian noise was introduced into the random sampling strategy to prevent the policy network from falling into local optima during the initial training stage while enhancing the model's performance and robustness. The model was effectively trained using a proximal policy optimization algorithm. Finally, the trained model was validated on a farmland test set, and the optimal path was selected using a greedy action selection strategy, resulting in an optimized solution for cross-county harvester scheduling. To verify the algorithm's effectiveness, four combined operation scenarios were considered, based on effective operation durations of 40 and 24 h, with the agricultural machinery scheduling center located at the center and edge of the operation area, respectively. The DRL-ICOSA algorithm, genetic algorithm (GA), particle swarm optimization (PSO), and simulated annealing (SA) were used to calculate scheduling strategies and conduct comparative analysis. The experimental results indicate that: when the scheduling center is located at the center or edge of the area and the effective operation duration is 40h, the DRL-ICOSA algorithm reduces the average scheduling cost by no less than 13.9% compared to the GA, PSO, and SA algorithms; when the effective operation duration is 24 h, the average scheduling cost reduction is no less than 11.5%. when the operation duration is 40 or 24 h and the scheduling center is located at the center of the area, the DRL-ICOSA algorithm reduces the average scheduling cost by no less than 12.3% compared to the GA, PSO, and SA algorithms; when the scheduling center is located at the edge of the area, the average scheduling cost reduction is no less than 11.5% for the DRL-ICOSA algorithm compared to the GA, PSO, and SA algorithms. Therefore, regardless of the effective operation duration or the geographical location of the scheduling center, the DRL-ICOSA algorithm consistently achieves the lowest scheduling cost compared to the other three algorithms. In summary, this study provides a more scientific and reasonable scheduling solution for the complex problem of collaborative harvester scheduling operations. The DRL-ICOSA algorithm demonstrates outstanding effectiveness in reducing scheduling costs and shows significant potential and application value in addressing the optimization problem of collaborative harvester scheduling. Compared with traditional heuristic algorithms, the proposed method is more suitable for complex environments and possesses stronger generalization capabilities. It avoids the manual feature design steps of traditional methods, thereby reducing dependence on prior knowledge. This study can effectively reduce resource waste and cost expenditure.

Keywords: agricultural machinery; optimization algorithm; path planning; deep reinforcement learning; cooperative scheduling